بسم الله الرحمن الرحیم

پروژه صفر درس مبانی علوم داده

دکتر بهرک و دکتر یعقوب زاده

محمد امین توانایی - ۸۱۰۱۰۱۳۹۶

سید علی تهامی - ۸۱۰۱۰۱۳۹۷

مهدی وجهی - ۸۱۰۱۰۱۵۵۸

فهرست

مقدمه

با توجه به گسترش روزافزون استفاده از رمز ارز ها از جمله اتریوم تحلیل و زیر نظر گرفتن تبادلات آن می تواند از جنبه های مختلفی کاربرد داشته باشد. در این پروژه با استفاده از ابزار جمع آوری اطلاعات ابتدا اطلاعات را از سایت etherscan.io جمع آوری می کنیم و سپس با کمک باقی ابزار ها داده را تمیز می کنیم و آن را تحلیل می کنیم.

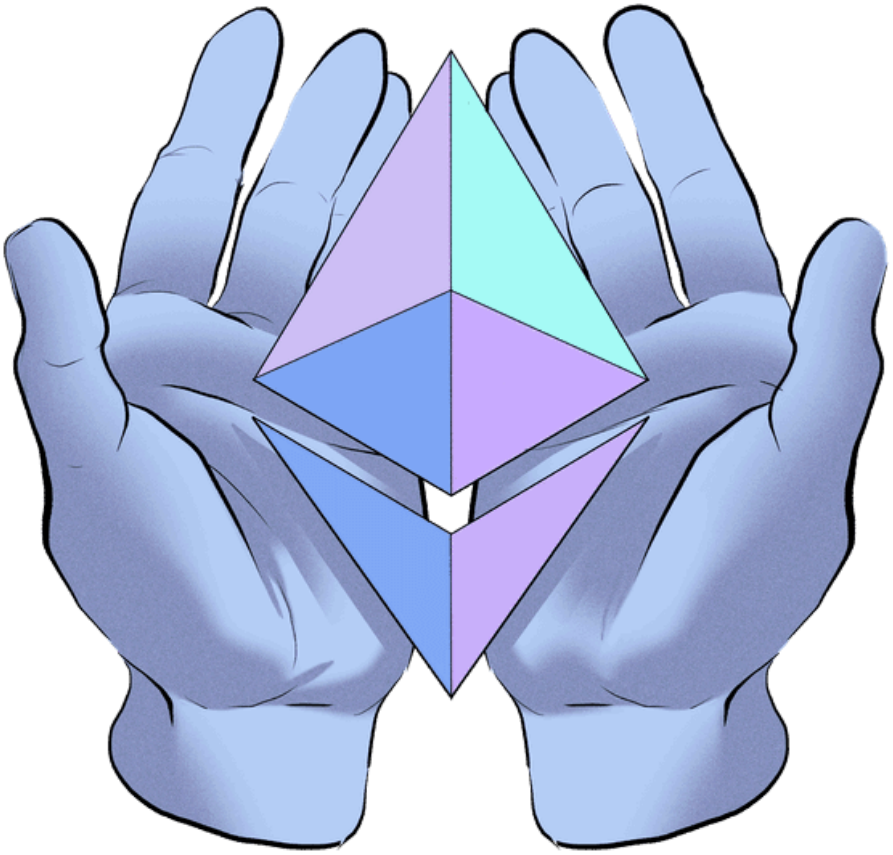

آماده سازی محیط

در این قسمت باید کتابخانه ها و ابزار مورد نیاز را نصب کنیم. برای برنامه یک فایل `requirements.txt` می نویسیم که کتابخانه ها در آن نوشته شده:

```
bs4
selenium
pandas
numpy
matplotlib
seaborn
plotly
scipy
```

سپس می توانیم با دستور زیر کتابخانه ها را نصب کنیم:

```
pip install -r requirements.txt
```

حال باید یک web driver نصب کنیم که از پیوند مربوطه از گیت هاب نسخه مناسب مرورگر خودمان را دانلود می کنیم.

جمع آوری اطلاعات

راه اندازی

ابتدا ابزار خود را با کد زیر امتحان می کنیم که درست نصب شده باشند.

```
from selenium import webdriver
from selenium.webdriver.common.by import By
from bs4 import BeautifulSoup

driver = webdriver.Firefox()
driver.get("https://etherscan.io/txs")
```

که در نتیجه ی آن مرورگر باز می شود:

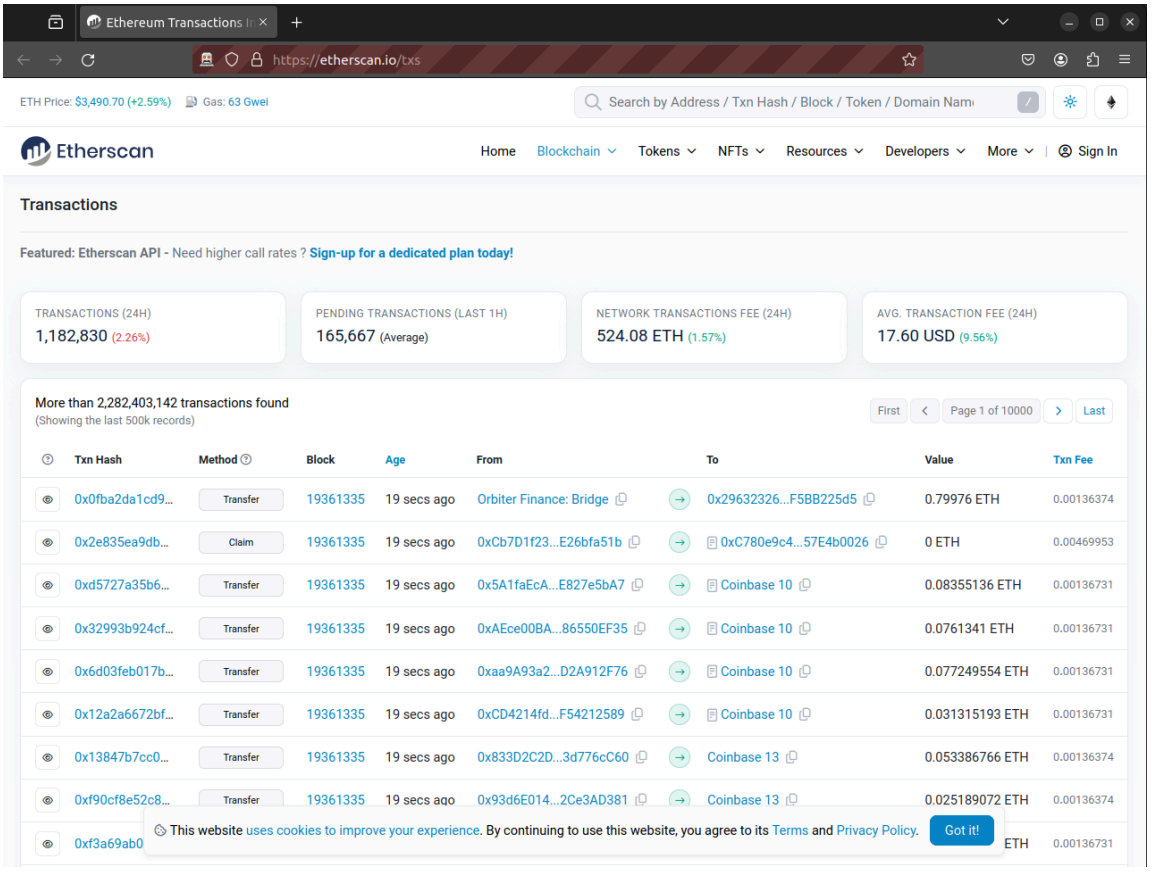

حال ساختار صفحه را بررسی می کنیم:

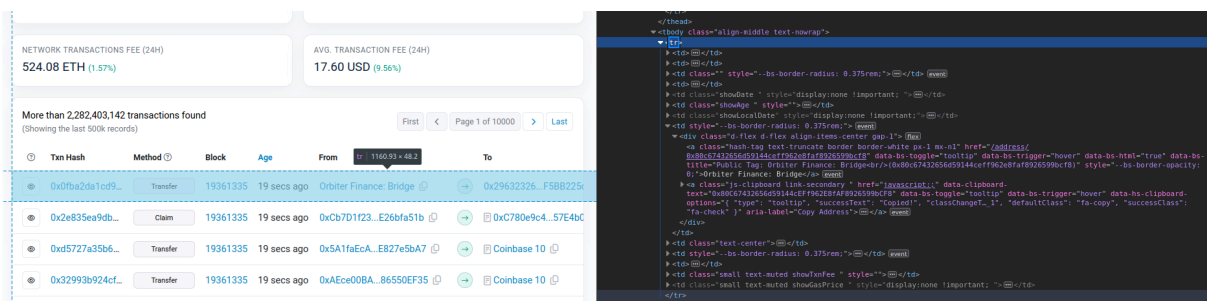

همانطور که در تصویر می بینیم داده های مورد نظر ردیف های یک جدول هستند (تگ های tr یک تگ tbody) و هر خانه آن (تگ td) یک داده هستند. با کتابخانه bs4 صفحه را تجزیه می کنیم و قسمت مربوطه را پیدا می کنیم.

```
the_soup = BeautifulSoup(driver.page_source, 'html.parser')
t = the_soup.find("tbody", attrs={"class":"align-middle text-nowrap"})
```

حال باید تگ های tr را از آن استخراج کنیم و نتیجه را تا به اینجا بررسی کنیم:

```
row = [i for i in t.children]
str(row[1].text)
```

```
'\n\n\n\n\n\n0x0fba2da1cd9b331ccda63a48b0cd1ee4de7d0424f5c4cf26cf807f20c
5a5f909\n\n\nTransfer\n19361335\n2024-03-04 10:55:2319 secs
ago1709549723\n\n\nOrbiter Finance: Bridge\n
\n\n\n\n\n\n0x29632326...F5BB225d5\n \n\n0.79976
ETH\n0.0013637464.94033407\n'
```

حال هر ردیف را به td می شکنیم:

```
for i in range(1, 10):
   print(i, row[i].findAll("td")[2].text)
```

```
1 Transfer
2 Claim
3 Transfer
4 Transfer
5 Transfer
6 Transfer
7 Transfer
8 Transfer
9 Transfer
```

حال باید محتوای هر کدام از خانه ها را بررسی کنیم:

```
for i in range(len(row[1].findAll("td"))):
      print(i, repr(str(row[1].findAll("td")[i].text)))
```

```
0 '\n\n'
1
'\n\n0x0fba2da1cd9b331ccda63a48b0cd1ee4de7d0424f5c4cf26cf807f20c5a5f909\
n\n'
2 'Transfer'
3 '19361335'
```

```
4 '2024-03-04 10:55:23'
5 '19 secs ago'
6 '1709549723'
7 '\n\nOrbiter Finance: Bridge\n \n'
8 '\n\n'
9 '\n\n0x29632326...F5BB225d5\n \n'
10 '0.79976 ETH'
11 '0.00136374'
12 '64.94033407'
```

مقادیر با همان ترتیب شماره ها داری مقدار های زیر هستند:

محتوا	شماره
-	۰
خطا ها و Txn Hash	۱
Method(بعضی نام ها به طور کامل نیست)	۲
Block	۳
زمان به صورت ساعت - تاریخ	۴
زمان گذشته تا به حال	۵
زمان به ثانیه	۶
From	۷
اگر تبادل از یک فرد به خودش باشد مقدار SELF می گیرد	۸
To	۹
Value	۱۰
Txn Fee	۱۱
GasPrice	۱۲

مقدار های هر کدام از این موارد در یکی از زیر مجموعه های تگ td است مثلا برای Method در یک text یک span ذخیره شده پس با کد زیر خوانده می شود:

```
td.find("span").text
```

حل مشکل دوباره خوانده شدن یک تراکنش

با بررسی سایت متوجه می شویم که بلوک های جدید به سرعت در حال تولید هستند و طول هر یک ممکن است به بیش از ۸ صفحه نیز برسد بنابراین اگر ما بخواهیم داده را صفحه به صفحه بخوانیم با این مشکل مواجه می شویم که وقتی داده های چند صفحه را خواندیم با تولید یک بلوک جدید تراکنش ها چندین صفحه به عقب بروند و داده ها مجددا خوانده شوند یا حتی به دلیل بالا بودن سرعت تولید بلوک ممکن است اصلا به آخرین بلوک نرسیم. حل این مشکل پیچیده نیست، با بررسی سایت متوجه می شویم می شود تراکنش های فقط یک بلوک را در صفحه ای با پیوندی به شکل زیر مشاهده کرد:

```
https://etherscan.io/txs?block={block}&p={page_number}
```

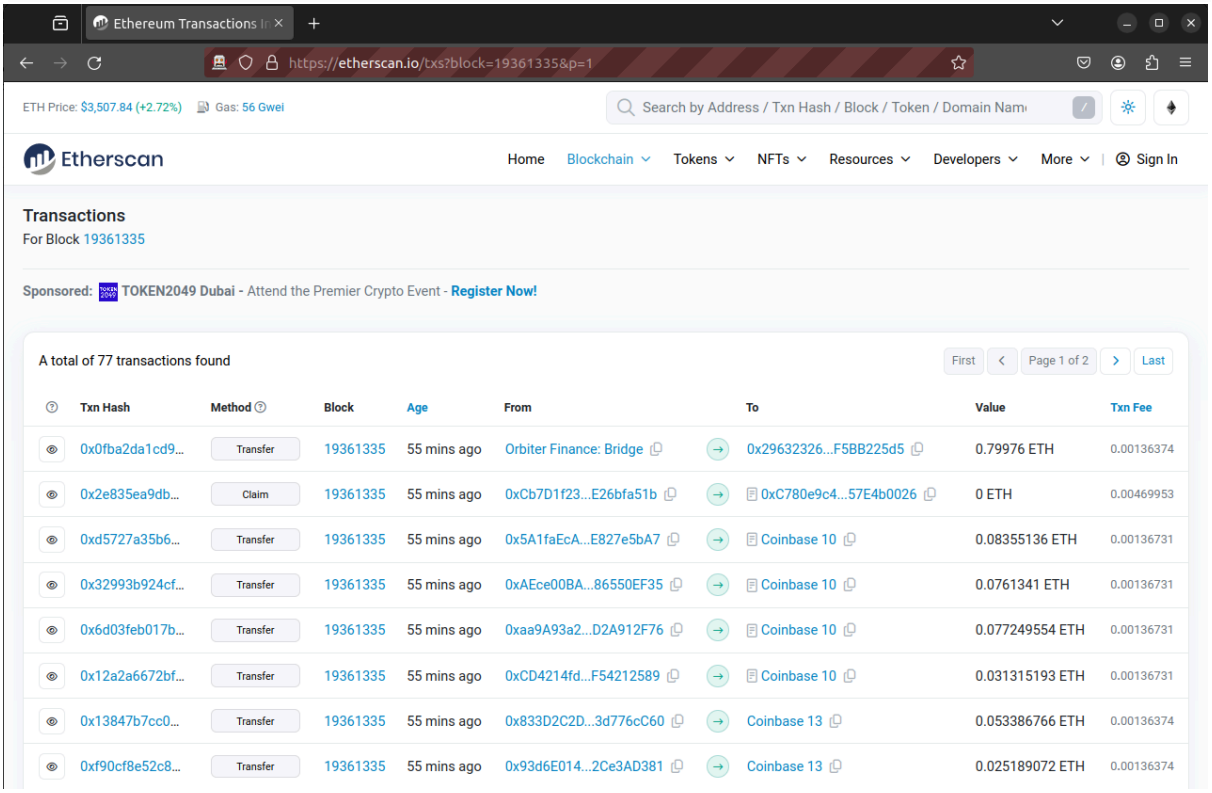

راه حل بالا ایراد گفته شده را برطرف می کند.

طراحی استخراج کننده

حال که با ساختار سایت آشنا شدیم باید کدی بنویسیم که اطلاعات ۱۰ بلوک آخر را استخراج کند. برای این کار لازم است برنامه روند زیر را داشته باشد:

1. باز کردن سایت
2. خواندن عدد آخرین بلوک
3. خواندن بلوک ها
    a. ساخت پیوند مرتبط با هر بلوک
    b. ورود به صفحه اول بلوک و خواندن تعداد صفحات برای ساخت پیوند مناسب

c. خواندن و ذخیره کردن هر صفحه
   i. تجزیه جدول تبادلات به ردیف ها
   ii. تبدیل داده html به قالب مناسب
   iii. ذخیره در اطلاعات آن بلوک
   iv. رفتن به صفحه بعدی
4. ذخیره داده ها در فایل با قالب مناسب

تابع scrape_data

این تابع، تابع اصلی برنامه است که به صورت زیر است:

```
def scrape_data():
      driver = open_page()
      first_block = find_first_block(driver)
      data = read_blocks(driver, first_block)
      write_in_json_file(data)
```

همانطور که می بینید گام های زیر برای استخراج طی می شود:

1. باز کردن صفحه (open_page)
2. پیدا کردن اولین بلوک(find_first_block)
3. خواندن بلوک ها(read_blocks)
4. ثبت اطلاعات در فایل (write_in_json_file)

تابع open_page

این تابع مسئولیت باز کردن مرورگر و سپس سایت را دارد و در آخر هم driver سلنیوم را برای کار های بعدی بر می گرداند.

```
def open_page():
      driver = webdriver.Firefox()
      driver.get("https://etherscan.io/txs")
      return driver
```

تابع find_first_block

این تابع تراکنش های صفحه اول را می خواند (parse_transaction) و شماره بلوک آخرین تراکنش را بر می گرداند.

```
def find_first_block(driver) -> int:
      the_soup = BeautifulSoup(driver.page_source, 'html.parser')
      return int(parse_transaction(the_soup)[1]["Block"])
```

تابع read_blocks

این تابع برای ۱۰ بلاک آخر، تابع collect_block_data را صدا می زند و تراکنش های آنها را ذخیره می کنید. نکته قابل توجه این است که برای این که سایت ما را مسدود نکند و فکر نکند ربات هستیم یک ثانیه بین آنها تاخیر می گذاریم.

```
def read_blocks(driver, first_block) -> list[dict]:
      output = list()
      for i in range(BLOCK_COUNT):
            output.extend(collect_block_data(driver, first_block - i))
            print(f"sample block {first_block - i}: {output[-1]}\n")
            time.sleep(1)
      return output
```

تابع write_in_json_file

این تابع نکته خاصی ندارد و صرفا خروجی را در یک فایل json ذخیره می کند.

```
def write_in_json_file(data_list):
      json_data = json.dumps(data_list, indent=4)

      file_path =
f"data_block_{data_list[0]['Block']}_{data_list[-1]['Block']}.json"
      with open(file_path, "w") as file:
            file.write(json_data)

      print(f"Data has been saved to {file_path}")
```

تابع parse_transaction

این تابع تراکنش های یک صفحه را استخراج می کند. همانطور که قبلا توضیح دادیم این تابع جدول تراکنش ها را به ردیف ها تجزیه می کند و به تابع convert_row_to_dict می دهد. همچنین در صورت فعال کردن log نمونه ای از تراکنش ها را نمایش می دهد.

```
def parse_transaction(the_soup, log=False):
      table = the_soup.find("tbody", attrs={"class":"align-middle
text-nowrap"})
      rows = [i for i in table.children]
      if log:
      print(f"--------\nsample row:
{str(rows[1])[:300]}...\n----------\n")
      row_data = [convert_row_to_dict(rows[i]) for i in range(1,
len(rows) - 1)]
      if log:
      print(f"--------\nsample data: {row_data[1]}\n----------\n")
```

```
    return row_data
```

تابع collect_block_data

هدف این تابع خواندن تراکنش های یک بلوک است.

این تابع روند زیر را طی می کند:

1. باز کردن صفحه مربوط به بلوک
2. خواندن تعداد صفحات تراکنش یک بلوک (get_page_count)
3. پیمایش صفحات و خواندن آن صفحات (parse_transaction)

```
def collect_block_data(driver, block):
    block_data = list()
    driver.get(f"https://etherscan.io/txs?block={block}")
    the_soup = BeautifulSoup(driver.page_source, 'html.parser')
    page_count = get_page_count(the_soup)
    for page_number in range(1, page_count + 1):

driver.get(f"https://etherscan.io/txs?block={block}&p={page_number}")
    the_soup = BeautifulSoup(driver.page_source, 'html.parser')
    block_data.extend(parse_transaction(the_soup))
    return block_data
```

تابع convert_row_to_dict

این تابع ردیف های جدول را می گیرد و به فرمت دیکشنری با محتوای زیر تبدیل می کند:

1. هش معامله
2. روش معامله
3. شماره بلاک
4. زمان به تاریخ-ساعت
5. مبدا تراکنش
6. متغیر بولی آیا مبدا و مقصد تراکنش یکسانند
7. مقصد تراکنش
8. مقدار
9. مقدار مالیات
10. GasPrice
11. ارور ها

موارد بالا را با بررسی html و زیر مجموعه های td به دست می آید مثلا می بینیم که مقدار block در تگ span ذخیره شده است. باقی موارد هم به حالت مشابه به دست می آید.

```
def convert_row_to_dict(row):
```

```
      cells = row.findAll("td")
      return {"Txn Hash": cells[1].find("a").text,
            "Method": cells[2].find("span").text,
            "Block": cells[3].find("a").text,
            "Time": cells[4].find("span").text,
            "From": cells[7].find("a")["data-bs-title"] if
cells[7].find("a").has_attr('data-bs-title')\
            else cells[7].find("span")["data-bs-title"],
            "Self": cells[8].text == "SELF",
            "To": cells[9].find("a")["data-bs-title"] if
cells[9].find("a").has_attr('data-bs-title')\
            else cells[9].find("span")["data-bs-title"],
            "Value": cells[10].text,
            "Txn Fee": cells[11].text,
            "GasPrice": cells[12].text,
            "Error": cells[1].findAll("span")[0]["data-bs-title"]\
            if len(cells[1].findAll("span")) > 1 else ""}
```

```
{'Txn Hash':
'0x5830f362d58d12323ebad2285016faa45bd25276ab4b76c3bbe80a6f60205a1f',
 'Method': 'Transfer',
 'Block': '19347624',
 'Time': '2024-03-02 12:56:59',
 'From': 'Public Tag:
beaverbuild<br/>(0x95222290dd7278aa3ddd389cc1e1d165cc4bafe5)',
 'Self': False,
 'To': '0xd6e4aa932147a3fe5311da1b67d9e73da06f9cef',
 'Value': '0.04264153 ETH',
 'Txn Fee': '0.00133034',
 'GasPrice': '47.24401969',
 'Error': ''}
```

تابع get_page_count

تگ مربوط به را پیدا می کنیم و مقدار آن را بر می گردانیم.

```
def get_page_count(the_soup):
      return int(the_soup.find(class_="page-link
text-nowrap").text.split()[3])
```

آنالیز داده ها

در این قسمت باید داده هایی که در قسمت قبل گرفتیم را آنالیز کنیم.

بارگذاری داده ها

برای بارگذاری داده ها کار خاصی لازم به انجام نیست و فقط کافیست کد زیر را اجرا کنیم:

```
df = pd.read_json("./data_block_19347625_19347616.json")
df
```

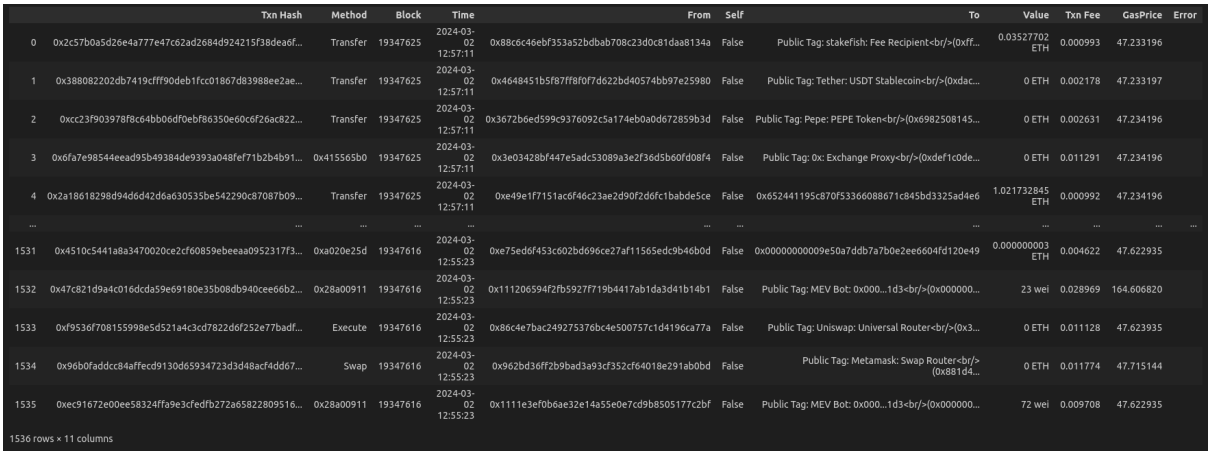

	Txn Hash	Method	Block	Time	From	Self	To	Value	Txn Fee	GasPrice	Error
0	0x2c57b0a5d26e4a777e47c62ad2684d924215f38dea6f...	Transfer	19347625	2024-03-02 12:57:11	0x88c6c46ebf353a52bdbab708c23d0c81daa8134a	False	Public Tag: stakefish: Fee Recipient (0xff...	0.03527702 ETH	0.000993	47.233196	
1	0x388082202db7419cfff90deb1fcc01867d83988ee2ae...	Transfer	19347625	2024-03-02 12:57:11	0x4648451b5f87ff8f0f7d622bd40574bb97e25980	False	Public Tag: Tether: USDT Stablecoin (0xdac...	0 ETH	0.002178	47.233197	
2	0xcc23f903978f8c64bb06df0ebf86350e60c6f26ac822...	Transfer	19347625	2024-03-02 12:57:11	0x3672b6ed599c9376092c5a174eb0a0d672859b3d	False	Public Tag: Pepe: PEPE Token (0x6982508145...	0 ETH	0.002631	47.234196	
3	0x6fa7e98544eead95b49384de9393a048fef71b2b4b91...	0x415565b0	19347625	2024-03-02 12:57:11	0x3e03428bf447e5adc53089a3e2f36d5b60fd08f4	False	Public Tag: 0x: Exchange Proxy (0xdef1c0de...	0 ETH	0.011291	47.234196	
4	0x2a18618298d94d6d42d6a630535be542290c87087b09...	Transfer	19347625	2024-03-02 12:57:11	0xe49e1f7151ac6f46c23ae2d90f2d6fc1babde5ce	False	0x652441195c870f53366088671c845bd3325ad4e6	1.021732845 ETH	0.000992	47.234196	
...	...	...	...	...	...	...	...	...	...	...	...
1531	0x4510c5441a8a3470020ce2cf60859ebeeaa0952317f3...	0xa020e25d	19347616	2024-03-02 12:55:23	0xe75ed6f453c602bd696ce27af11565edc9b46b0d	False	0x00000000009e50a7ddb7a7b0e2ee6604fd120e49	0.000000003 ETH	0.004622	47.622935	
1532	0x47c821d9a4c016dcda59e69180e35b08db940cee66b2...	0x28a00911	19347616	2024-03-02 12:55:23	0x111206594f2fb5927f719b4417ab1da3d41b14b1	False	Public Tag: MEV Bot: 0x000...1d3 (0x000000...	23 wei	0.028969	164.606820	
1533	0xf9536f708155998e5d521a4c3cd7822d6f252e77badf...	Execute	19347616	2024-03-02 12:55:23	0x86c4e7bac249275376bc4e500757c1d4196ca77a	False	Public Tag: Uniswap: Universal Router (0x3...	0 ETH	0.011128	47.623935	
1534	0x96b0faddcc84affecd9130d65934723d3d48acf4dd67...	Swap	19347616	2024-03-02 12:55:23	0x962bd36ff2b9bad3a93cf352cf64018e291ab0bd	False	Public Tag: Metamask: Swap Router (0x881d4...	0 ETH	0.011774	47.715144	
1535	0xec91672e00ee58324ffa9e3cfedfb272a65822809516...	0x28a00911	19347616	2024-03-02 12:55:23	0x1111e3ef0b6ae32e14a55e0e7cd9b8505177c2bf	False	Public Tag: MEV Bot: 0x000...1d3 (0x000000...	72 wei	0.009708	47.622935	

1536 rows × 11 columns

پاکسازی داده ها

با توجه به مواردی که توضیح دادیم در داده ها، داده تکراری نداریم فقط مشکلی که وجود دارد این است که ارزش معامله گاهی به wei است که با یک جست و جوی ساده متوجه می شویم که ۱۰ به توان -۱۸ اتر ارزش دارد پس با کد زیر داده ها را تبدیل می کنیم:

```
df['Value'] = df['Value'].apply(
      lambda val: float(val.split()[0]) *
      (1 if val.split()[1] == "ETH" else (10 ** -18 if val.split()[1] ==
"wei" else Exception("??"))))
```

همچنین ستون های زمان را از قالب رشته به قالب زمان می بریم:

```
df["Time"] = pd.to_datetime(df["Time"])
```

آنالیز آماری

در این قسمت متغیر های ارزش معامله و مالیات معامله را مورد بررسی قرار می دهیم. جدول زیر برخی از متغیر های آماری مربوط به داده ها را نشان می دهد.

متغیر آماری	با در نظر گرفتن تراکنش های صفر		بدون در نظر گرفتن تراکنش های صفر	
	Value	Txn Fee	Value	Txn Fee
میانگین	0.670632	0.005073	1.459054	0.003097
میانه	0.000000	0.002366	0.057348	0.001066
انحراف معیار	13.044758	0.009911	19.211157	0.004013
IQR	0.045676	0.004909	0.282837	0.004271

without zero

	Value	Txn Fee	GasPrice
count	706.000000	706.000000	706.000000
mean	1.459054	0.003097	51.516851
std	19.224778	0.004016	18.340651
min	0.000000	0.000980	46.678019
25%	0.013132	0.001014	47.434373
50%	0.057349	0.001066	49.033394
75%	0.295970	0.005286	50.724862
max	500.000000	0.052443	361.503483
median	0.057349	0.001066	49.033394
IQR	0.282838	0.004271	3.290489

with zero

	Value	Txn Fee	GasPrice
count	1536.000000	1536.000000	1536.000000
mean	0.670633	0.005073	50.953806
std	13.049007	0.009915	15.700495
min	0.000000	0.000980	46.678019
25%	0.000000	0.001082	47.301360
50%	0.000000	0.002366	48.678019
75%	0.045677	0.005992	50.301624
max	500.000000	0.121668	361.503483
median	0.000000	0.002366	48.678019
IQR	0.045677	0.004909	3.000264

نکات قابل توجه در داده ها:

- بیش از ۵۰ درصد داده ها صفر هستند.
- تفاوت میانه و میانگین بسیار زیاد است معادل ۱.۵ اتر یعنی چیزی حدود ۴۵۰۰$!!! دلیل این موضوع این است که پارامتر هایی مانند میانگین به داده های پرت حساس هستند ولی میانه نیست همین موضوع برای IQR و انحراف معیار صادق است به طوری که از IQR می توان نتیجه گرفت اختلاف تبادلات ۰.۲۸ اتر است اما انحراف معیار ۱۹.۲۲ اتر این مقدار را محاسبه می کند.
- برخلاف دو داده دیگر gas price میانگین و میانه نزدیک به یکدیگر دارد.
- یک تبادل ۵۰۰ اتری معادل ۱.۸۰۰.۰۰۰$ داریم.

بررسی بیشتر تبادل ۵۰۰ اتری

تبادل به شرح زیر است:

	Txn Hash	Method	Block	Time	From	Self	To	Value	Txn Fee	GasPrice
677	0x0c8141f52e2009804a25e7a23ad68993af0a07179c0a...	Transfer	19347621	2024-03-02 12:56:23	0x4196c40de33062ce03070f058922baa99b28157b	False	Public Tag: Lido: wstETH Token (0x7f39c581...	500.0	0.006144	50.747998

فرد فرستنده تبادلات زیر را داشته:

	Txn Hash	Method	Block	Time	From	Self	To	Value	Txn Fee	GasPrice
677	0x0c8141f52e2009804a25e7a23ad68993af0a07179c0a...	Transfer	19347621	2024-03-02 12:56:23	0x4196c40de33062ce03070f058922baa99b28157b	False	Public Tag: Lido: wstETH Token (0x7f39c581...	500.0	0.006144	50.747998
1300	0x845a2fdd441097b91044aea49f8261bdf5a48ddadea6...	Withdraw ETH	19347617	2024-03-02 12:55:35	0x4196c40de33062ce03070f058922baa99b28157b	False	0x893411580e590d62ddbca8a703d61cc4a8c7b2b9	0.0	0.018911	47.079028

فرد دریافت کننده را با اسمش جستجو کردیم و به تراکنش های زیر رسیدیم:

	Txn Hash	Method	Block	Time	From	Self	To	Value	Txn Fee	GasPrice
445	0xdfaf3e1ae4e26ef195cdecce7f483b20f63735a9f07b...	Approve	19347623	2024-03-02 12:56:47	0x4dc921de85561bca35d33ca15c19f2e1e5043590	False	Public Tag: Lido: stETH Token (0xae7ab9652...	0.000000	0.002168	50.069108
470	0xbe991696be31477650f01ca7197bd0a471a655b25478...	Transfer	19347623	2024-03-02 12:56:47	Public Tag: Binance 16 (0xdfd5293d8e347dfe...	False	Public Tag: Lido: LDO Token (0x5a98fcbea51...	0.000000	0.006703	51.279108
496	0xed1f0965a9b24cc3e30375062f9ffdc1abb7b2e19388...	Transfer	19347622	2024-03-02 12:56:35	Public Tag: Titan Builder (0x4838b106fce96...	False	Public Tag: Lido: Execution Layer Rewards Vaul...	0.056132	0.001101	49.809176
677	0x0c8141f52e2009804a25e7a23ad68993af0a07179c0a...	Transfer	19347621	2024-03-02 12:56:23	0x4196c40de33062ce03070f058922baa99b28157b	False	Public Tag: Lido: wstETH Token (0x7f39c581...	500.000000	0.006144	50.747998
705	0xb3dbe655b904df10da63534bf96a1641baf3a28925e9...	Approve	19347621	2024-03-02 12:56:23	0xaeddc5c90df91d8a9f1e9ec96aee93e64c8f045a	False	Public Tag: Lido: stETH Token (0xae7ab9652...	0.000000	0.003328	50.742275
903	0x23589249d4e5beeac45f0ca096221abeb8e0d7d32c8b...	Approve	19347620	2024-03-02 12:56:11	0xe81032708386337d65678303678caf2597f315e9	False	Public Tag: Lido: stETH Token (0xae7ab9652...	0.000000	0.003102	47.302860
956	0x05434d3467ade2997c5ce99715b64ef3e4cc9169a9db...	Transfer	19347619	2024-03-02 12:55:59	Public Tag: Faith Builder (0x5124fcc2b3f99...	False	Public Tag: Lido: Execution Layer Rewards Vaul...	0.014163	0.001068	48.291462

نام دریافت کننده را در اینترنت جستجو می کنیم و می بینیم که بزرگ ترین pool شبکه اتریوم هست و دارایی ای معادل ۳۵.۰۰۰.۰۰۰.۰۰۰$ دارد.

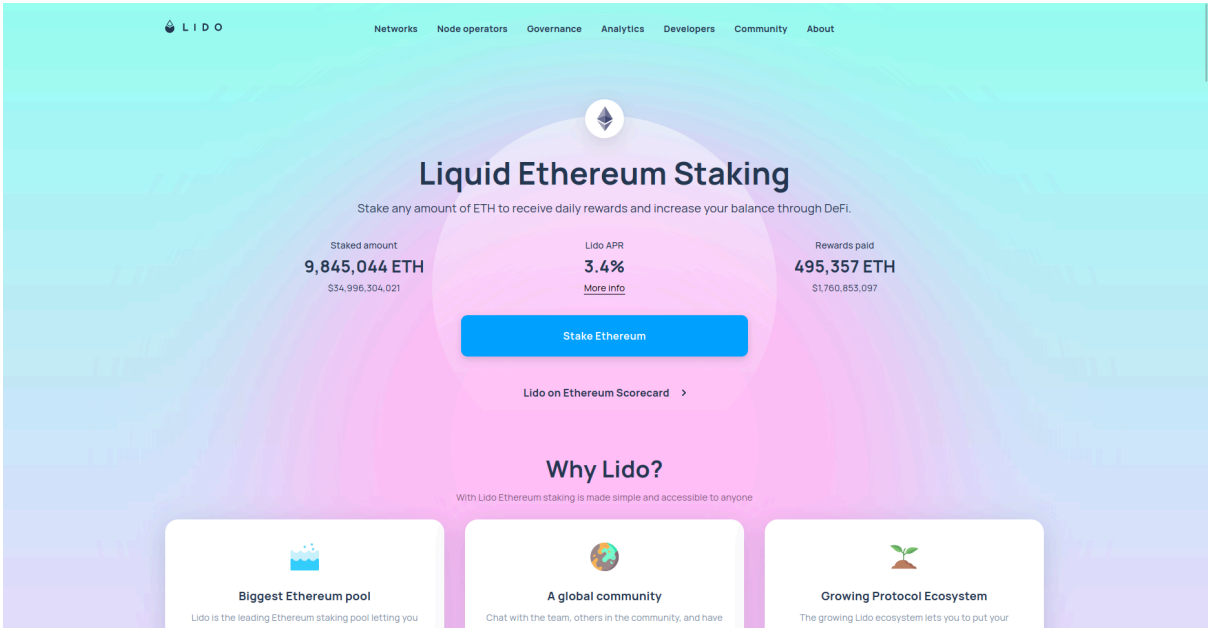

بصری سازی داده ها

ما بصری سازی داده را در ۳ حالت انجام می دهیم:

- داده های خام
- لگاریتم داده ها
- لگاریتم داده ها با حذف صفر ها

داده های خام

در این حالت نمودار های معنا داری نمی گیریم اما نمودار ها به شرح زیر هستند:

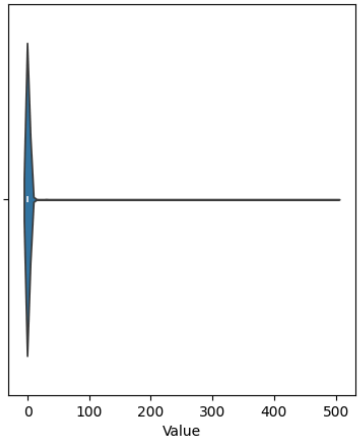

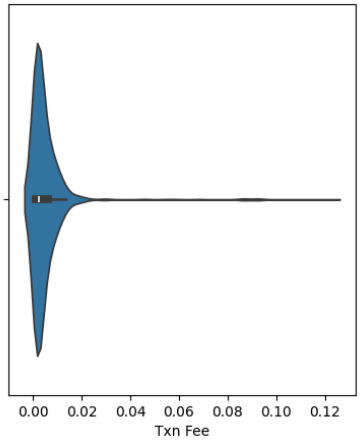

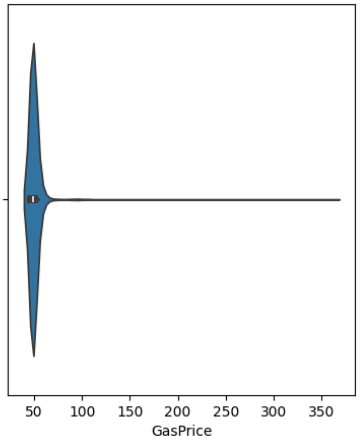

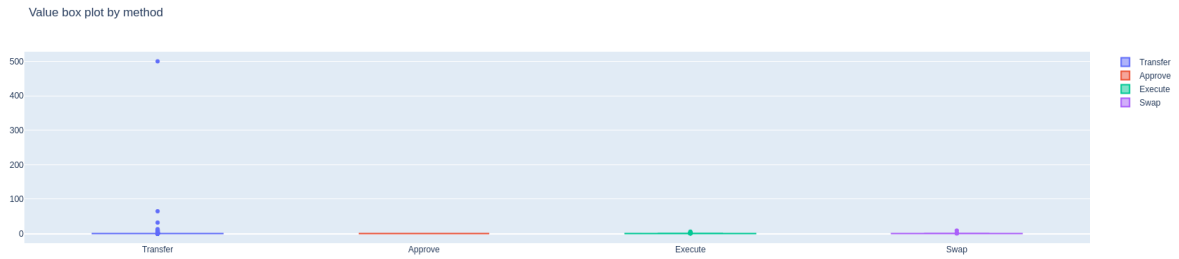

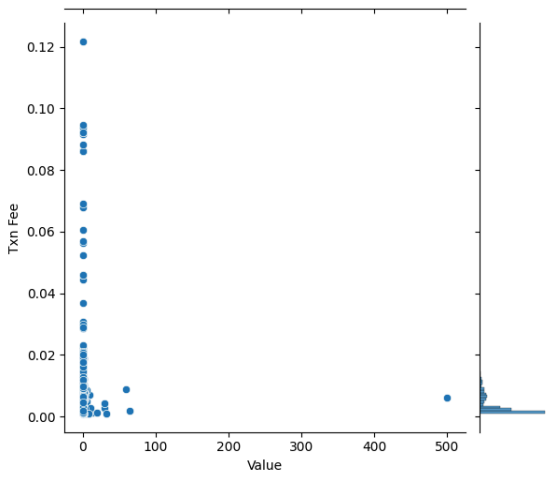

لگاریتم داده ها

لگاریتم داده ها را می گیریم و برای ۰ ها مقدار اپسیلون (۱۰ به توان منفی ۲۵) را قرار می دهیم.

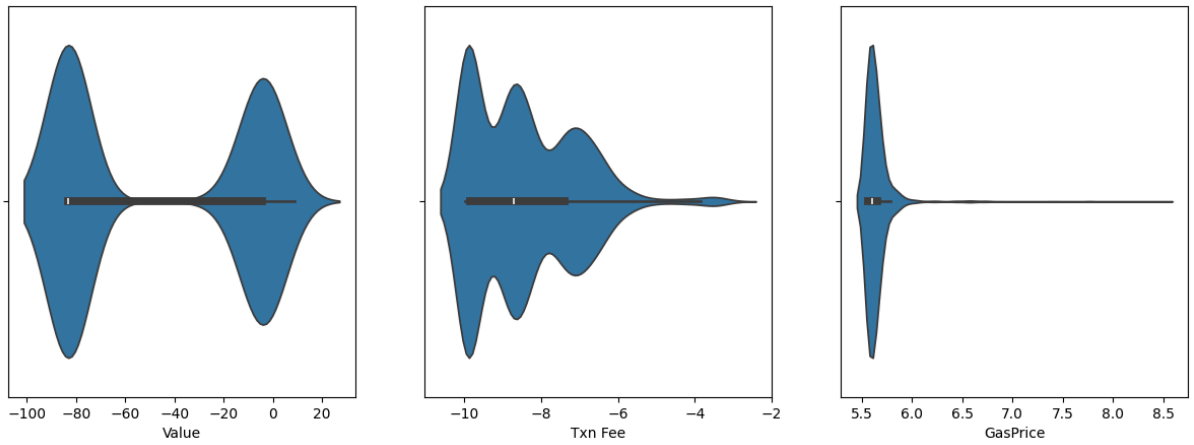

از نمودار ویالون موارد زیر را متوجه می شویم:

- نمودار value مدالیتی bimodal است. (به دلیل داده های صفر)
- نمودار txn fee مدالیتی multimodal است.
- نمودار gas price مدالیتی unimodal است.

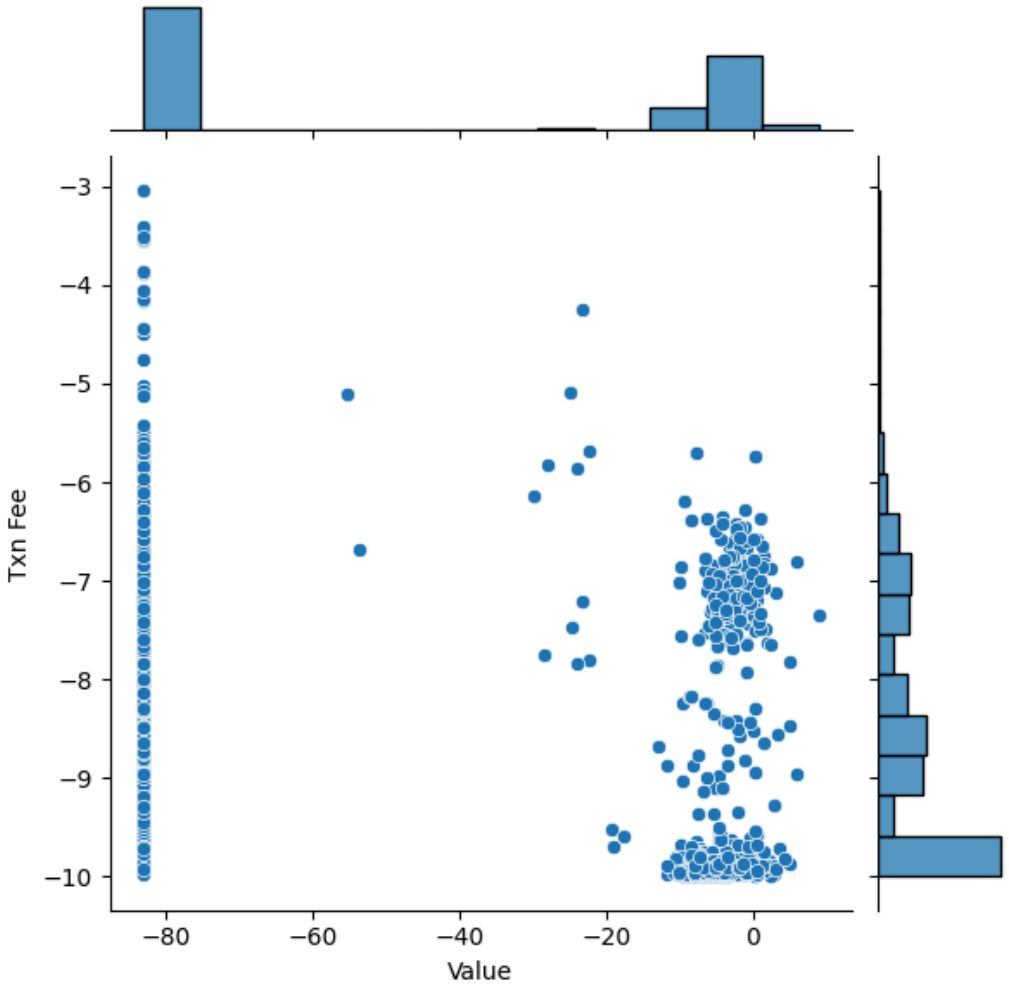

در سمت چپ نمودار بالا داده های صفر تجمیع شده اند.

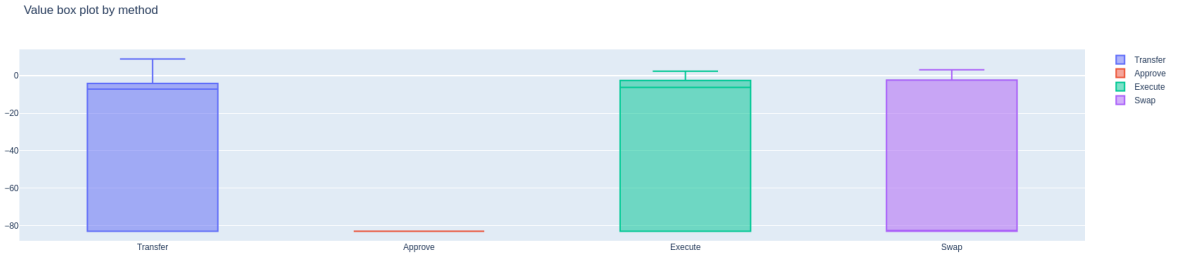

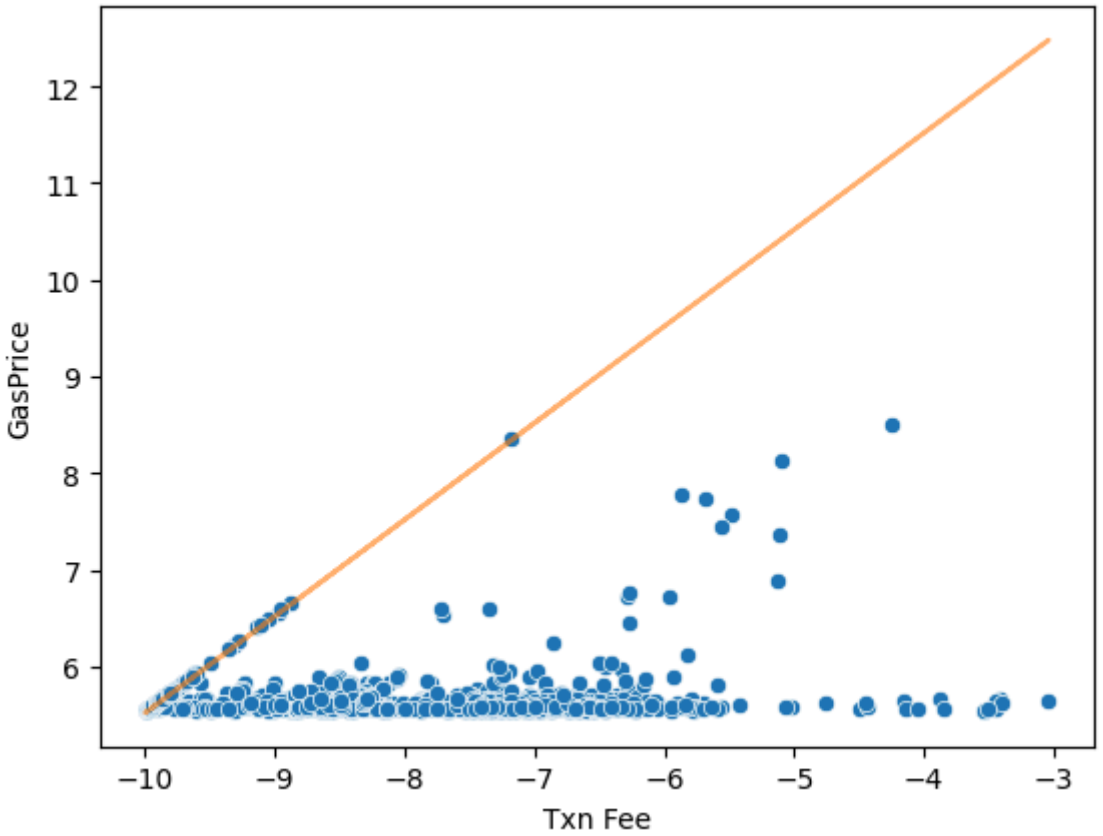

در نمودار بالا به نظر می آید که رابطه زیر برقرار است.

$$GasPrice \leq TxnFee + C$$

لگاریتم داده ها با حذف صفر ها

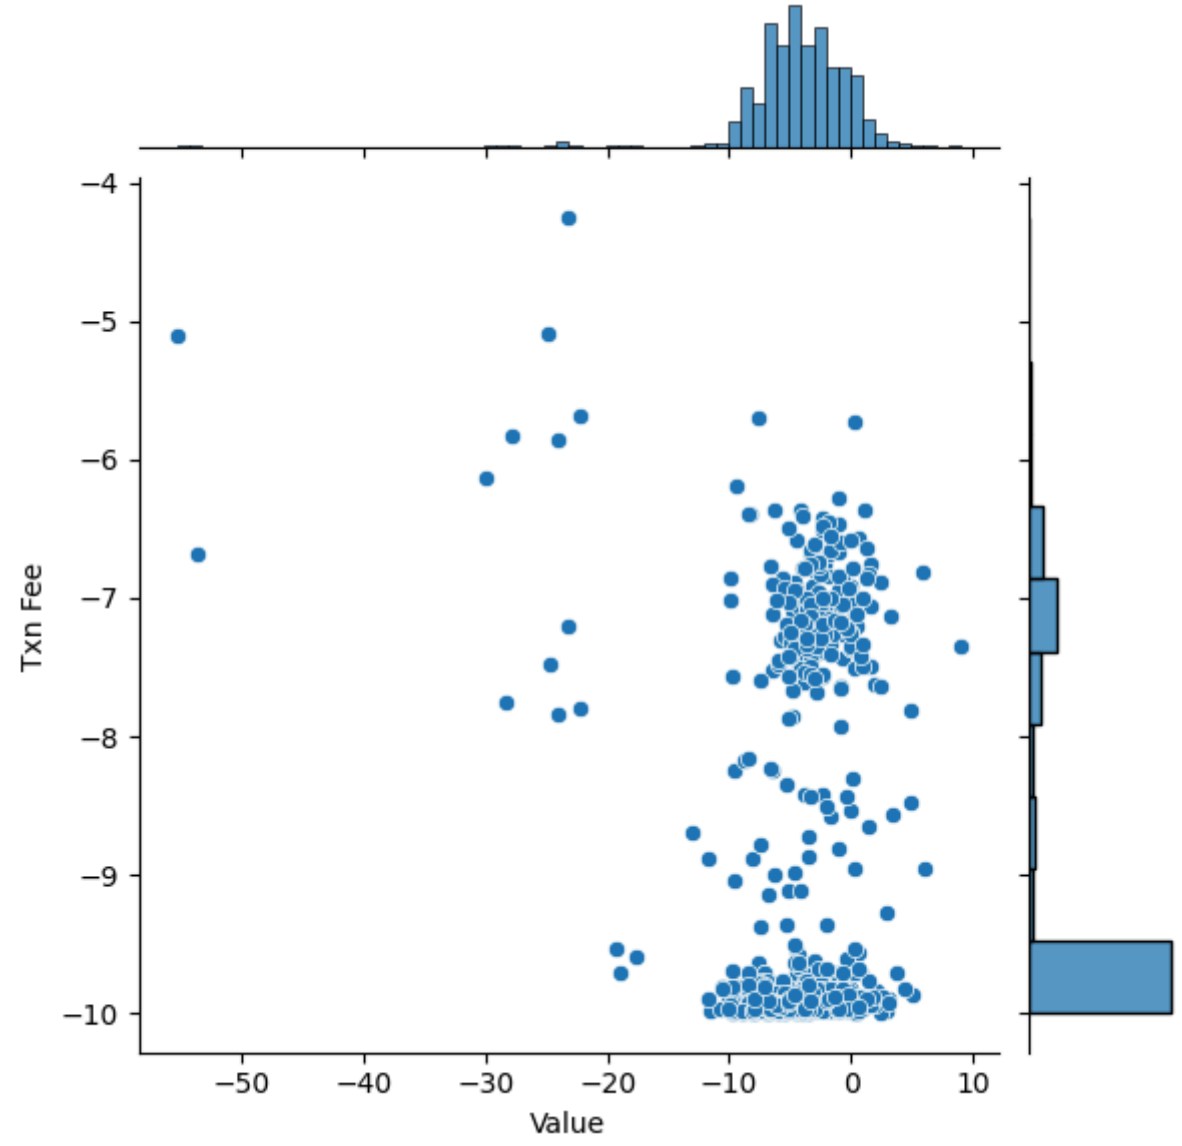

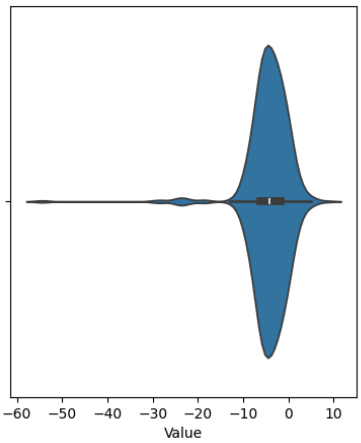

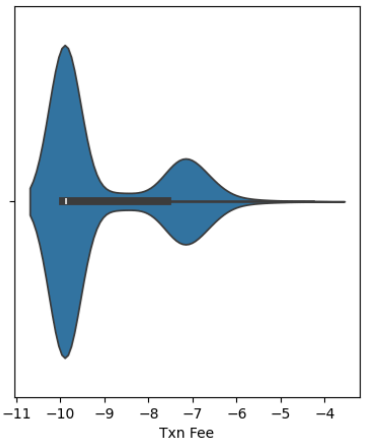

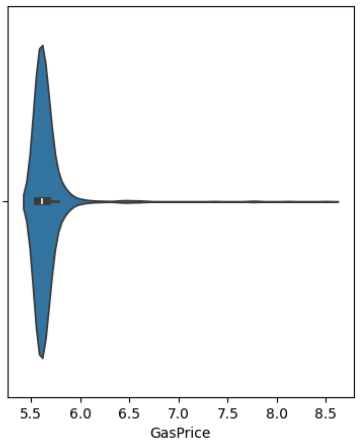

روی این داده ها توزیع نرمال فیت می کنیم:

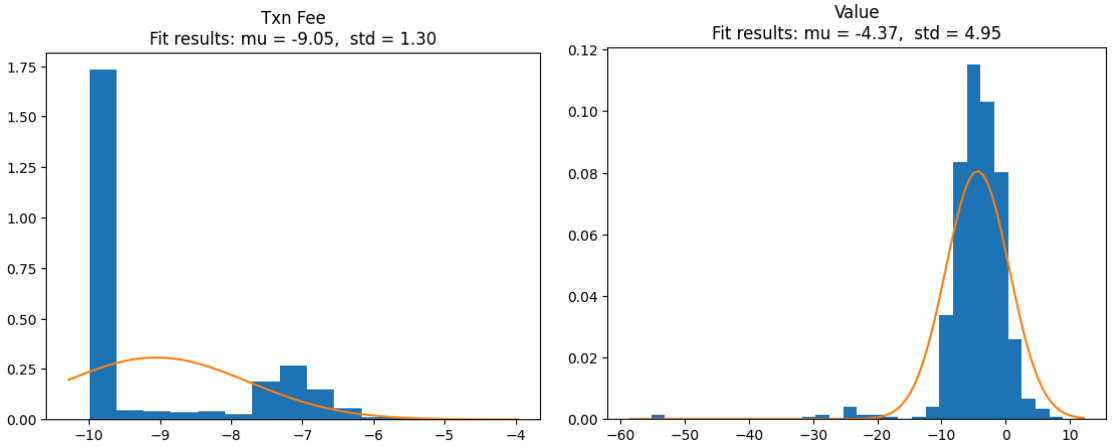

همانطور که می بینید value تقریبا از توزیع نرمال پیروی می کند ولی txn fee اینطور نیست.

نمونه گیری

پراکندگی داده

چون پراکندگی داده در این دیتاست زیاد بود تصمیم گرفتم که برای نمایش داده ها از log آنها استفاده کنم و بنابر اینکه تعداد زیادی داده صفر بود مینیمم داده را گرفتم و از صفر ها را بعلاوه عددی از چند مرتبه کمتر از عدد مینیمم کردم.

```
for i in range(len(df)):
    if df.at[i,'Value']==0:
        df.at[i,'Value']+=1e-25
```

برای راحتی در کار و از دست نرفتن داده به همان دیتا فریم قبلی ستون هایی اضافه کردم که صرفا لگاریتم ستون value بر مبنای ۱۰ و لگاریتم ستون Txn Fee را بر پایه دو گرفتم.(چون value پراکندگی بیشتری نسبت به Txn Fee داشت)

```
df.insert(10,"log10_value",[math.log10(df.at[i,'Value']*10**18) for i in
range(len(df))])
df.insert(11,"log2_fee",[math.log2(df.at[i,'Txn Fee']) for i in
range(len(df))])
```

توجه : برای درک بهتر چون هر eth ده توان هیجده wei است برای همین تبدیل واحد به اتریوم انجام دادم.

توجه : از قسمت ذیل به آخر تصمیم بر این بوده که تعداد نمونه یک بیستم تعداد جامعه باشد.

نمونه گیری تصادفی

تصمیم بر این گرفتم که تعداد نمونه ۵ درصد تعداد دیتاست باشد.اطلاعات این نمونه گیری به شرح زیر بود.

دقت شود ۱e-۲۵ همان صفر است

	Value	Txn Fee
count	7.700000e+01	77.000000
mean	1.421553e-01	0.004687
std	4.482033e-01	0.008280
min	1.000000e-25	0.000988
25%	1.000000e-25	0.001056
50%	1.000000e-25	0.002359
75%	2.494750e-02	0.005471
max	2.500000e+00	0.067792

sample

	Value	Txn Fee
count	1.536000e+03	1536.000000
mean	6.706330e-01	0.005073
std	1.304901e+01	0.009915
min	1.000000e-25	0.000980
25%	1.000000e-25	0.001082
50%	1.000000e-25	0.002366
75%	4.567656e-02	0.005992
max	5.000000e+02	0.121668

population

در اینجا مشاهده میکنیم که اختلاف بین انحراف معیار نمونه و جامعه زیاد است.

توجیح : در جامعه چند داده پرت بسیار بزرگ وجود دارد که بر روی انحراف معیار تاثیر می گذارد همانطور که انحراف معار یک داده حساس به outlier است. برای همین انحراف معیار جامعه افزایش می یابد اما در نمونه گیری احتمال انتخاب outlier بسیار کم است پس در اکثر اوقات انتخاب نمی شود .پس انحراف معیار کاهش پیدا میکند.

برای اینکه تحلیل درستی از نمونه داشته باشیم نیاز به چارک ها نیز داریم زیرا آنها به outlier حساس نیستند.

همانطور که مشاهده میشود در نمونه و جامعه چارک ها نزدیک به هم هستند.

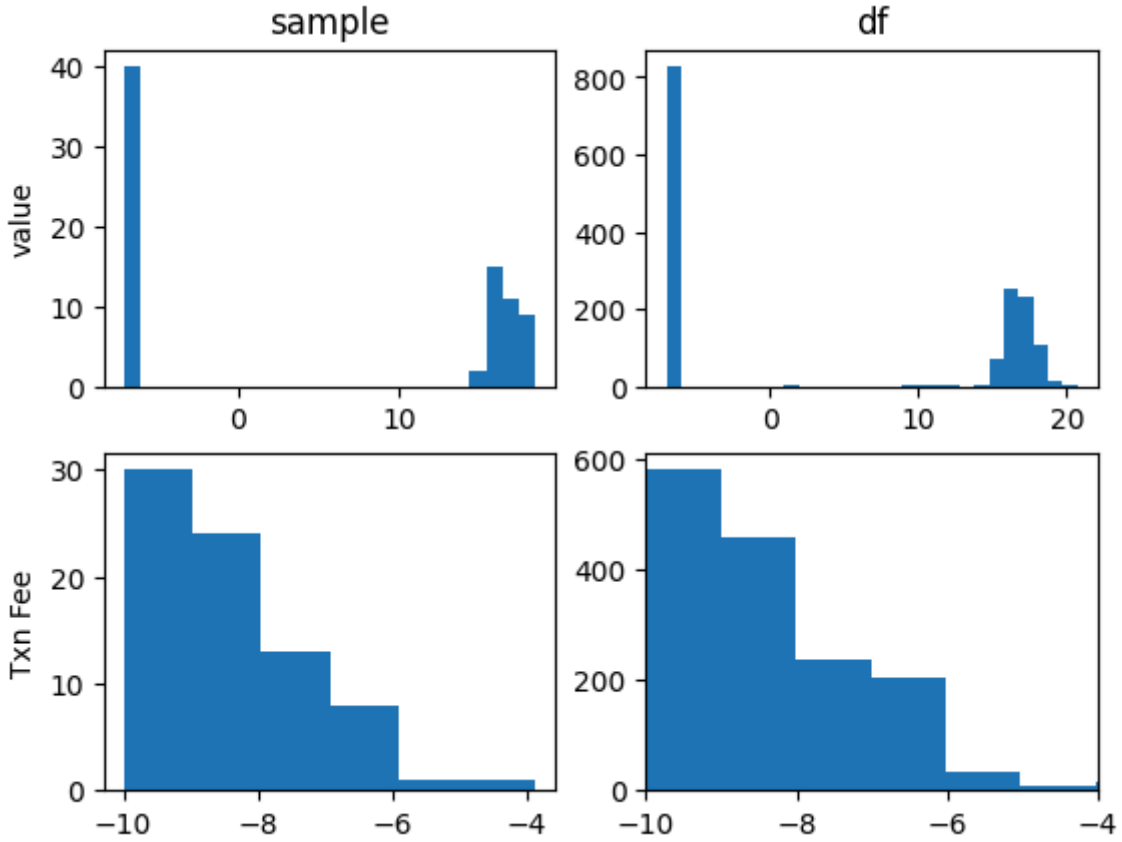

این هم نمودار های مربوط به جامعه و نمونه که مربوط به ستون های value و Txn Fee است نمایش داده شده است.مشاهده میشود که نمودار ها شبیه به هم است.(در کشیدن این نمودار ها چون از داده ها لگاریتم گرفته شده و نمایش داده شده اند و اختلاف بازه عددی کم است در انتخاب bins از فرمول - max (min hsjthni ani hsj.

توجه : دقت شود واحد لگاریتم گرفته شده wei است و داده های منفی در نمودار value نشان دهنده صفر است.

نمونه گیری طبقه ای

در این قسمت من سه نوع مختلف نمونه گیری انجام دادم و برای هر کدام دلایل آنها را نیز ذکر کرده ام.

طبقه بندی بر اساس مقدار

چون مقدار ها از صفر تا ۱۰ بتوان بیست wei قابل تغییرند و نزدیک به صفر دیتا بسیار بیشتری وجود دارد من برای اینکه دیتا های بزرگ هم شانس انتخاب داشته باشند دیتا ست را بر اساس لگاریتم بر پایه ۱۰ بصورت بازه های به طول یک مرتب کردم.

```
"""I want to sample that stratified by value thus i classify value with
line bellow"""
df.insert(0,"Value_Category",[round(math.log10(df.at[i,'Value']*10**18))
for i in range(len(df)) ],True)
proportionate_stratified_sample_based_on_value =
df.groupby('Value_Category', group_keys=False).apply(lambda x:
x.sample(frac =SAMPLE_PERCENT))
proportionate_stratified_sample_based_on_value[["Value","Txn
Fee"]].describe()
```

	Value	Txn Fee
count	1.536000e+03	1536.000000
mean	6.706330e-01	0.005073
std	1.304901e+01	0.009915
min	1.000000e-25	0.000980
25%	1.000000e-25	0.001082
50%	1.000000e-25	0.002366
75%	4.567656e-02	0.005992
max	5.000000e+02	0.121668

population

	Value	Txn Fee
count	7.600000e+01	76.000000
mean	1.531477e-01	0.004526
std	4.780717e-01	0.008254
min	1.000000e-25	0.000980
25%	1.000000e-25	0.001056
50%	1.000000e-25	0.002491
75%	5.413221e-02	0.005553
max	3.361160e+00	0.069124

sample

	Value	Txn Fee
count	7.600000e+01	76.000000
mean	1.531477e-01	0.004526
std	4.780717e-01	0.008254
min	1.000000e-25	0.000980
25%	1.000000e-25	0.001056
50%	1.000000e-25	0.002491
75%	5.413221e-02	0.005553
max	3.361160e+00	0.069124

Stratified by value

	Value	Txn Fee
count	7.700000e+01	77.000000
mean	1.421553e-01	0.004687
std	4.482033e-01	0.008280
min	1.000000e-25	0.000988
25%	1.000000e-25	0.001056
50%	1.000000e-25	0.002359
75%	2.494750e-02	0.005471
max	2.500000e+00	0.067792

random

همانطور که مشاهده می شود نمونه گیری طبقه ای که گرفته شده چنان فرقی با تصادفی ندارد و این نشان دهنده ی خوبی طبقه بندی ماست.

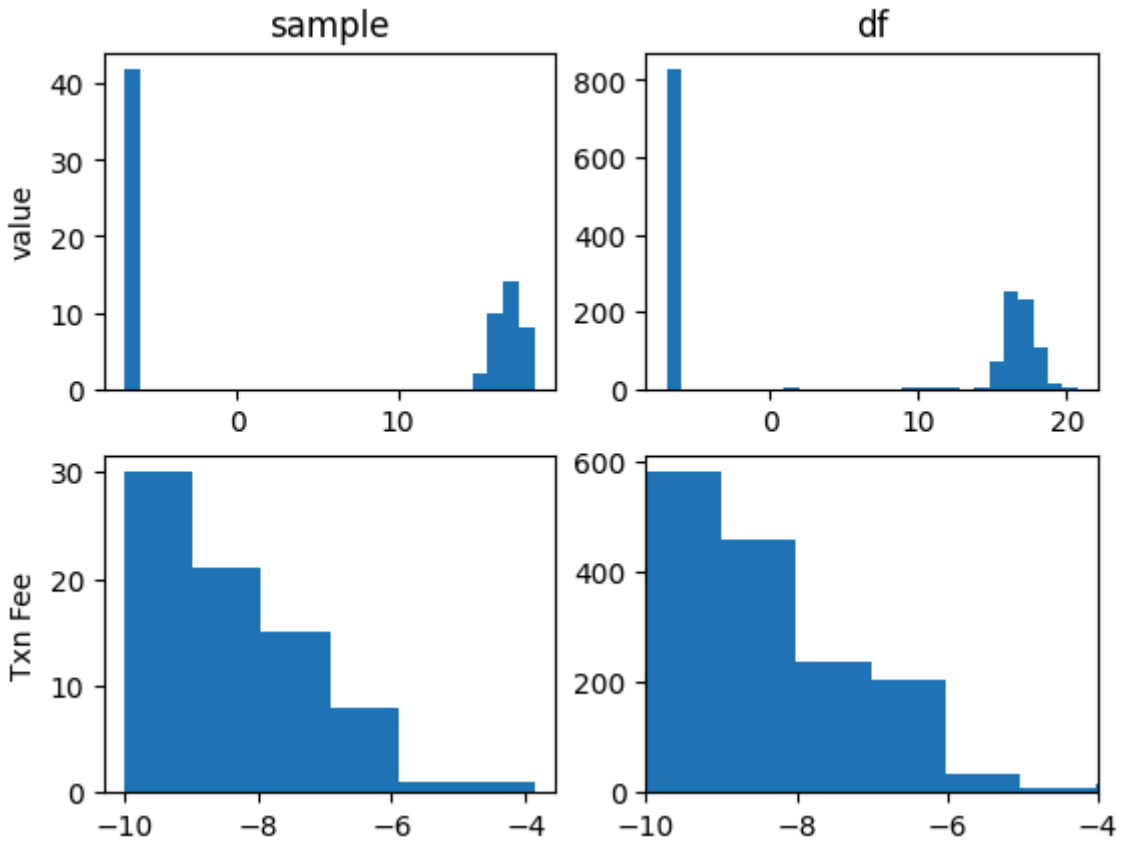

همانطور که دیده می شود نمونه گیری بسیار به واقعیت نزدیک است.

طبقه بندی بر اساس method

وقتی متد های مختلف را مشاهده کردم دیدم در هر متد مقدار پول های متفاوتی جابجا شده است برای همین آنها را طبقه بندی کرده و از هر کدام بر حسب وزنشان نمونه انتخاب کردم.

```
proportionate_stratified_sample_based_on_method = df.groupby('Method',
group_keys=False).apply(lambda x: x.sample(frac=SAMPLE_PERCENT))
proportionate_stratified_sample_based_on_method[["Value","Txn
Fee"]].describe()
```

	Value	Txn Fee
count	6.100000e+01	61.000000
mean	8.339925e+00	0.004456
std	6.400080e+01	0.012148
min	1.000000e-25	0.000988
25%	1.000000e-25	0.001067
50%	1.000000e-25	0.002204
75%	4.650000e-02	0.003112
max	5.000000e+02	0.094585

sample

	Value	Txn Fee
count	1.536000e+03	1536.000000
mean	6.706330e-01	0.005073
std	1.304901e+01	0.009915
min	1.000000e-25	0.000980
25%	1.000000e-25	0.001082
50%	1.000000e-25	0.002366
75%	4.567656e-02	0.005992
max	5.000000e+02	0.121668

population

مشاهده میکنید که در این نوع طبقه بندی نه تنها انحراف معیار پایینتر از مقدار جامعه نبود بلکه بالاتر از آن هم هست.

دلیل آن اینست که نمونه گیری ما اریب است زیرا چون نمونه گیری طبقه ای ما `proportionate` است پس باید در هر طبقه ۵ درصد تعداد آن طبقه انتخاب شود در صورتی که بسیاری از متد ها یکتا هستند و ۵ درصد آنها است پس از بسیاری از طبقه ها هیچ انتخابی انجام نمیشود.

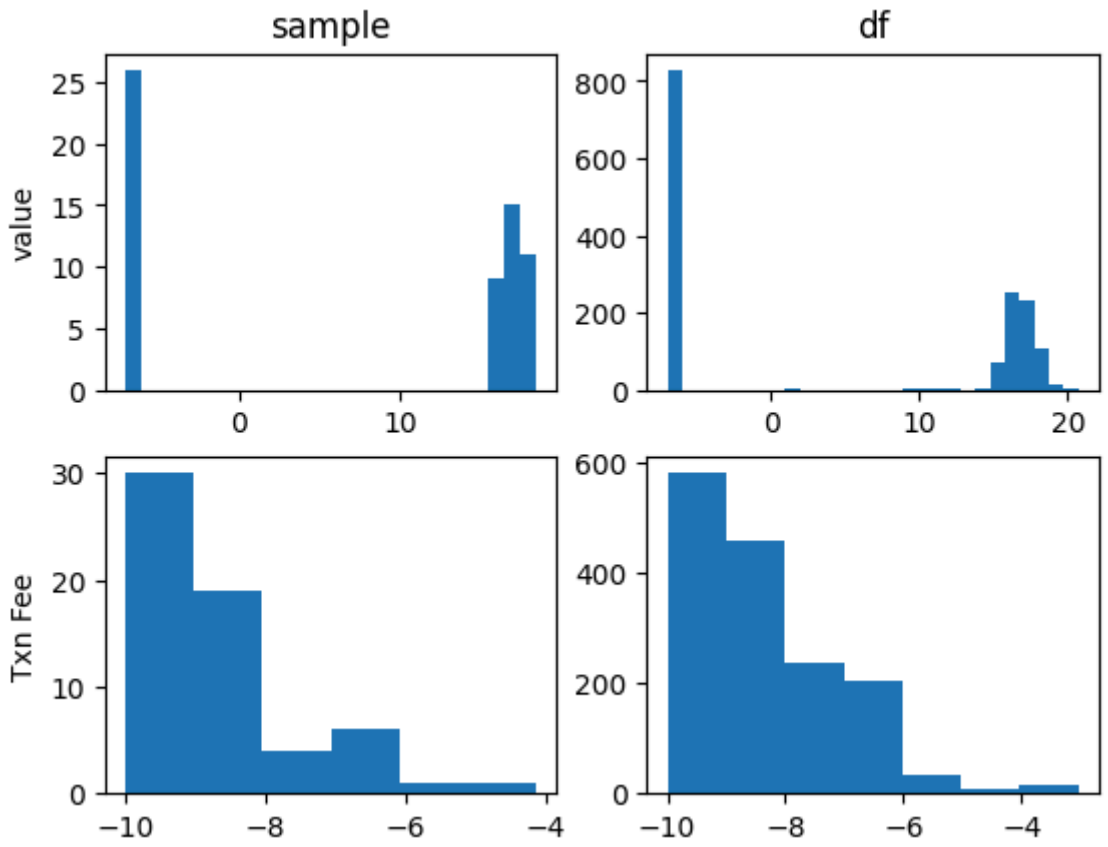

این اختلاف در نمودار ها نیز مشاهده میشود.

طبقه بندی بر اساس block

دلیل انتخاب من این بود که با اینکه نمیدانستم block ها چیست اما همینکه خود سایت اتریوم دسته بندی خود را بر اساس block های مختلف می گذارد یعنی block بندی معنا دار است و باعث تفاوت بین دیتا های هر block است.برای همین باید از هر block نمونه گیری انجام بگیرد.

```
proportionate_stratified_sample_based_on_blocks =
df.groupby('Block',group_keys=False).apply(lambda
x:x.sample(frac=SAMPLE_PERCENT))
proportionate_stratified_sample_based_on_blocks[["Value","Txn
Fee"]].describe()
```

	Value	Txn Fee
count	7.600000e+01	76.000000
mean	1.531445e-01	0.004888
std	6.483671e-01	0.005023
min	1.000000e-25	0.000988
25%	1.000000e-25	0.001181
50%	1.000000e-25	0.002977
75%	6.655000e-02	0.007599
max	5.490000e+00	0.028969

sample

	Value	Txn Fee
count	1.536000e+03	1536.000000
mean	6.706330e-01	0.005073
std	1.304901e+01	0.009915
min	1.000000e-25	0.000980
25%	1.000000e-25	0.001082
50%	1.000000e-25	0.002366
75%	4.567656e-02	0.005992
max	5.000000e+02	0.121668

population

باز هم تفاوت بین جامعه و نمونه کم است و صرفا به دلیلی که قبلا توضیح داده شد بین انحراف معیار نمونه و جامعه صرفا تفاوت وجود دارد.

پس این نشاندهنده از نا اریب بودن نمونه گیری طبقه ای ماست.

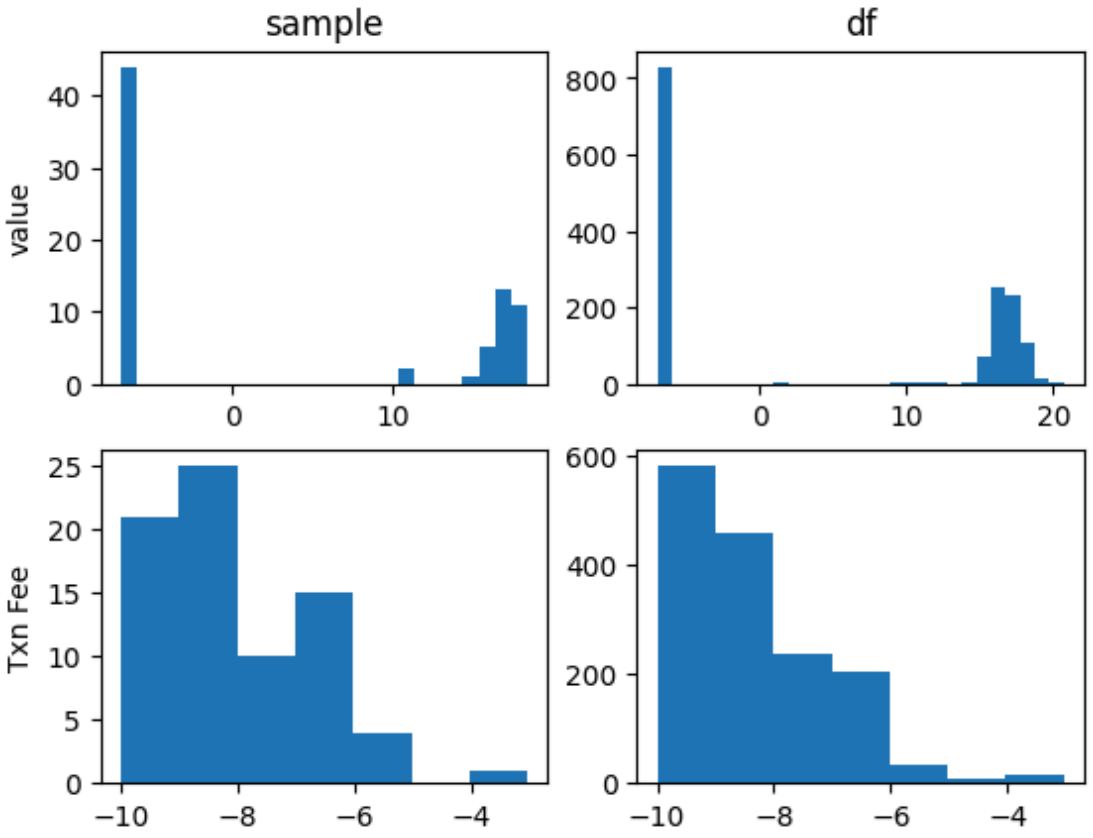

در نمودار ها نیز دیده می شود تفاوت چندانی بین نمونه و جامعه وجود ندارد.