# بسم الله الرحمن الرحيم

پروژه صفر درس مبانی علوم داده دکتر بهرک و دکتر یعقوب زاده

محمد امین توانایی - ۸۱۰۱۰۱۳۹۶ سید علی تهامی - ۸۱۰۱۰۱۳۹۷ مهدی وجهی - ۸۱۰۱۰۱۵۵۸

## فهرست

3	مقدمه
4	آماده سازی محیط
5	جمع آوری اطلاعات
5	راه اندازی
8	حل مشکل دوباره خوانده شدن یک تراکنش
8	طراحی استخراج کننده
9	تابع scrape_data تابع
9	تابع open_page
9	تابع find_first_block تابع
10	تابع read_blocks يابع
10	تابع write_in_json_file تابع
10	تابع parse_transaction
11	تابع collect_block_data تابع
11	تابع convert_row_to_dict تابع
12	تابع get_page_count تابع
13	آناليز داده ها
13	بارگذاری داده ها
13	پاکسازی داده ها
14	آنالیز آماری
15	بررسی بیشتر تبادل ۵۰۰ اتری
16	بصری سازی داده ها
16	داده های خام
17	لگاریتم داده ها
19	لگاریتم داده ها با حذف صفر ها

## مقدمه

با توجه به گسترش روزافزون استفاده از رمز ارز ها از جمله اتریوم تحلیل و زیر نظر گرفتن تبادلات آن می تواند از جنبه های مختلفی کاربرد داشته باشد. در این پروژه با استفاده از ابزار جمع آوری اطلاعات ابتدا اطلاعات را از سایت etherscan.io جمع آوری می کنیم و سپس با کمک باقی ابزار ها داده را تمیز می کنیم و آن را تحلیل می کنیم.



## آماده سازی محیط

در این قسمت باید کتابخانه ها و ابزار مورد نیاز را نصب کنیم. برای برنامه یک فایل requirements.txt می نویسیم که کتابخانه ها در آن نوشته شده:

```
bs4
selenium
pandas
numpy
matplotlib
seaborn
plotly
scipy
```

سپس می توانیم با دستور زیر کتابخانه ها را نصب کنیم:

```
pip install -r requirements.txt
```

حال باید یک web driver نصب کنیم که از پیوند مربوطه از گیت هاب نسخه مناسب مرورگر خودمان را دانلود می کنیم.

## جمع آوری اطلاعات

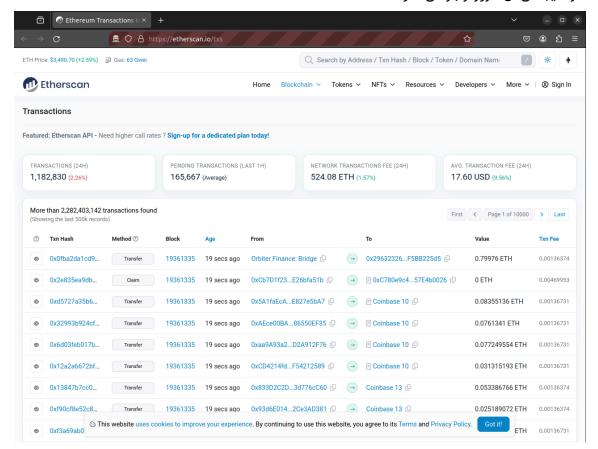
## راه اندازی

ابتدا ابزار خود را با کد زیر امتحان می کنیم که درست نصب شده باشند.

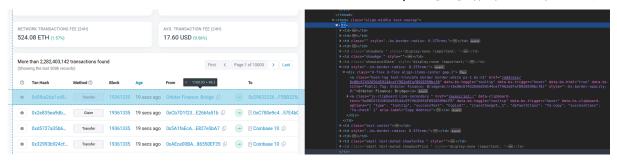
```
from selenium import webdriver
from selenium.webdriver.common.by import By
from bs4 import BeautifulSoup

driver = webdriver.Firefox()
driver.get("https://etherscan.io/txs")
```

#### که در نتیجه ی آن مرورگر باز می شود:



#### حال ساختار صفحه را بررسی می کنیم:



همانطور که در تصویر می بینیم داده های مورد نظر ردیف های یک جدول هستند ( تگ های tr یک تگ (tbody و هر خانه آن (تگ tb) یک داده هستند. با کتابخانه bs4 صفحه را تجزیه می کنیم و قسمت مربوطه را ییدا می کنیم.

```
the_soup = BeautifulSoup(driver.page_source, 'html.parser')
t = the_soup.find("tbody", attrs={"class":"align-middle text-nowrap"})
```

حال باید تگ های tr را از آن استخراج کنیم و نتیجه را تا به اینجا بررسی کنیم:

```
row = [i for i in t.children]
str(row[1].text)
```

'\n\n\n\n\n0x0fba2da1cd9b331ccda63a48b0cd1ee4de7d0424f5c4cf26cf807f20c5a5f909\n\nTransfer\n19361335\n2024-03-04 10:55:2319 secs ago1709549723\n\n\n0rbiter Finance: Bridge\n\n\n\n\n\n\n\n\n\x29632326...F5BB225d5\n\n\n0.79976 ETH\n0.0013637464.94033407\n'

حال هر ردیف را به td می شکنیم:

```
for i in range(1, 10):
    print(i, row[i].findAll("td")[2].text)
```

- 1 Transfer
- 2 Claim
- 3 Transfer
- 4 Transfer
- 5 Transfer
- 6 Transfer
- 7 Transfer
- 8 Transfer
- 9 Transfer

حال باید محتوای هر کدام از خانه ها را بررسی کنیم:

```
for i in range(len(row[1].findAll("td"))):
    print(i, repr(str(row[1].findAll("td")[i].text)))
```

```
0 '\n\n'
1
'\n\n0x0fba2da1cd9b331ccda63a48b0cd1ee4de7d0424f5c4cf26cf807f20c5a5f909\
n\n'
2 'Transfer'
3 '19361335'
```

```
4 '2024-03-04 10:55:23'
5 '19 secs ago'
6 '1709549723'
7 '\n\n0rbiter Finance: Bridge\n \n'
8 '\n\n'
9 '\n\n0x29632326...F5BB225d5\n \n'
10 '0.79976 ETH'
11 '0.00136374'
12 '64.94033407'
```

مقادیر با همان ترتیب شماره ها داری مقدار های زیر هستند:

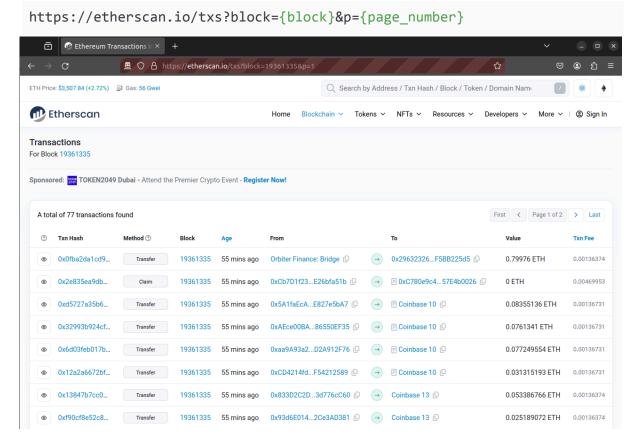
شماره	محتوا
0	-
1	خطا ها و Txn Hash
۲	(بعضی نام ها به طور کامل نیست)Method
٣	Block
k	زمان به صورت ساعت - تاریخ
۵	زمان گذشته تا به حال
۶	زمان به ثانیه
V	From
٨	اگر تبادل از یک فرد به خودش باشد مقدار SELF می گیرد
٩	То
10	Value
11	Txn Fee
או	GasPrice

صقدار های هر کدام از این موارد در یکی از زیر مجموعه های تگ td است مثلا برای Method در یک text یک span ذخیره شده پس با کد زیر خوانده می شود:

td.find("span").text

#### حل مشکل دوبارہ خواندہ شدن یک تراکنش

با بررسی سایت متوجه می شویم که بلوک های جدید به سرعت در حال تولید هستند و طول هر یک ممکن است به بیش از ۸ صفحه نیز برسد بنابراین اگر ما بخواهیم داده را صفحه به صفحه بخوانیم با این مشکل مواجه می شویم که وقتی داده های چند صفحه را خواندیم با تولید یک بلوک جدید تراکنش ها چندین صفحه به عقب بروند و داده ها مجددا خوانده شوند یا حتی به دلیل بالا بودن سرعت تولید بلوک ممکن است اصلا به آخرین بلوک نرسیم. حل این مشکل پیچیده نیست، با بررسی سایت متوجه می شویم می شود تراکنش های فقط یک بلوک را در صفحه ای با پیوندی به شکل زیر مشاهده کرد:



راه حل بالا ابراد گفته شده را برطرف می کند.

### طراحي استخراج كننده

حال که با ساختار سایت آشنا شدیم باید کدی بنویسیم که اطلاعات ۱۰ بلوک آخر را استخراج کند. برای این کار لازم است برنامه روند زیر را داشته باشد:

- 1. باز کردن سایت
- 2. خواندن عدد آخرین بلوک
  - 3. خواندن بلوک ها
- a. ساخت پیوند مرتبط با هر بلوک
- b. ورود به صفحه اول بلوک و خواندن تعداد صفحات برای ساخت پیوند مناسب

- c. خواندن و ذخیره کردن هر صفحه
- i. تجزیه جدول تبادلات به ردیف ها
- ii. تبدیل داده html به قالب مناسب
  - iii. ذخیره در اطلاعات آن بلوک
    - iv. رفتن به صفحه بعدی
    - 4. ذخیره داده ها در فایل با قالب مناسب

#### تابع scrape\_data

این تابع، تابع اصلی برنامه است که به صورت زیر است:

```
def scrape_data():
    driver = open_page()
    first_block = find_first_block(driver)
    data = read_blocks(driver, first_block)
    write_in_json_file(data)
```

همانطور که می بینید گام های زیر برای استخراج طی می شود:

- 1. باز کردن صفحه (<u>open\_page</u>)
- 2. پیدا کردن اولین بلوک(<u>find\_first\_block</u>)
  - 3. خواندن بلوک ها(<u>read\_blocks</u>)
- 4. ثبت اطلاعات در فایل (write\_in\_json\_file)

#### تابع open\_page

این تابع مسئولیت باز کردن مرورگر و سپس سایت را دارد و در آخر هم driver سلنیوم را برای کار های بعدی بر می گرداند.

```
def open_page():
    driver = webdriver.Firefox()
    driver.get("https://etherscan.io/txs")
    return driver
```

### تابع find\_first\_block

این تابع تراکنش های صفحه اول را می خواند (<u>parse\_transaction</u>) و شماره بلوک آخرین تراکنش را بر می گرداند.

```
def find_first_block(driver) -> int:
    the_soup = BeautifulSoup(driver.page_source, 'html.parser')
    return int(parse_transaction(the_soup)[1]["Block"])
```

#### تابع read\_blocks

این تابع برای ۱۰ بلاک آخر، تابع <u>collect\_block\_data</u> را صدا می زند و تراکنش های آنها را ذخیره می کنید. نکته قابل توجه این است که برای این که سایت ما را مسدود نکند و فکر نکند ربات هستیم یک ثانیه بین آنها تاخیر می گذاریم.

```
def read_blocks(driver, first_block) -> list[dict]:
    output = list()
    for i in range(BLOCK_COUNT):
        output.extend(collect_block_data(driver, first_block - i))
        print(f"sample block {first_block - i}: {output[-1]}\n")
        time.sleep(1)
    return output
```

#### write\_in\_json\_file تابع

این تابع نکته خاصی ندارد و صرفا خروجی را در یک فایل json ذخیره می کند.

```
def write_in_json_file(data_list):
    json_data = json.dumps(data_list, indent=4)

    file_path =
f"data_block_{data_list[0]['Block']}_{data_list[-1]['Block']}.json"
    with open(file_path, "w") as file:
        file.write(json_data)

    print(f"Data has been saved to {file_path}")
```

### تابع parse\_transaction

این تابع تراکنش های یک صفحه را استخراج می کند. همانطور که قبلا توضیح دادیم این تابع جدول تراکنش ها را به ردیف ها تجزیه می کند و به تابع convert row to dict می دهد. همچنین در صورت فعال کردن log نمونه ای از تراکنش ها را نمایش می دهد.

```
def parse_transaction(the_soup, log=False):
    table = the_soup.find("tbody", attrs={"class":"align-middle

text-nowrap"})
    rows = [i for i in table.children]
    if log:
        print(f"-----\nsample row:

{str(rows[1])[:300]}...\n------\n")
        row_data = [convert_row_to_dict(rows[i]) for i in range(1,
len(rows) - 1)]
    if log:
        print(f"-----\nsample data: {row_data[1]}\n-----\n")
```

#### return row data

#### تابع collect\_block\_data

هدف این تابع خواندن تراکنش های یک بلوک است.

این تابع روند زیر را طی می کند:

- 1. باز کردن صفحه مربوط به بلوک
- 2. خواندن تعداد صفحات تراکنش یک بلوک (get\_page\_count)
- 3. پیمایش صفحات و خواندن آن صفحات (<u>parse\_transaction</u>)

```
def collect_block_data(driver, block):
    block_data = list()
    driver.get(f"https://etherscan.io/txs?block={block}")
    the_soup = BeautifulSoup(driver.page_source, 'html.parser')
    page_count = get_page_count(the_soup)
    for page_number in range(1, page_count + 1):

driver.get(f"https://etherscan.io/txs?block={block}&p={page_number}")
    the_soup = BeautifulSoup(driver.page_source, 'html.parser')
    block_data.extend(parse_transaction(the_soup))
    return block_data
```

#### تابع convert\_row\_to\_dict

این تابع ردیف های جدول را می گیرد و به فرمت دیکشنری با محتوای زیر تبدیل می کند:

- 1. هش معامله
- 2. روش معامله
  - 3. شماره بلاک
- 4. زمان به تاریخ-ساعت
  - 5. مبدا تراکنش
- 6. متغیر بولی آیا مبدا و مقصد تراکنش یکسانند
  - 7. مقصد تراكنش
    - 8. مقدار
  - 9. مقدار مالیات
    - GasPrice .10
      - 11. ارور ها

موارد بالا را با بررسی html و زیر مجموعه های td به دست می آید مثلا می بینیم که مقدار block در تگ span ذخیره شده است. باقی موارد هم به حالت مشابه به دست می آید.

```
def convert_row_to_dict(row):
```

```
cells = row.findAll("td")
      return {"Txn Hash": cells[1].find("a").text,
            "Method": cells[2].find("span").text,
            "Block": cells[3].find("a").text,
            "Time": cells[4].find("span").text,
            "From": cells[7].find("a")["data-bs-title"] if
cells[7].find("a").has attr('data-bs-title')\
            else cells[7].find("span")["data-bs-title"],
            "Self": cells[8].text == "SELF",
            "To": cells[9].find("a")["data-bs-title"] if
cells[9].find("a").has_attr('data-bs-title')\
            else cells[9].find("span")["data-bs-title"],
            "Value": cells[10].text,
            "Txn Fee": cells[11].text,
            "GasPrice": cells[12].text,
            "Error": cells[1].findAll("span")[0]["data-bs-title"]\
            if len(cells[1].findAll("span")) > 1 else ""}
```

```
{'Txn Hash':
'0x5830f362d58d12323ebad2285016faa45bd25276ab4b76c3bbe80a6f60205a1f',
'Method': 'Transfer',
'Block': '19347624',
'Time': '2024-03-02 12:56:59',
'From': 'Public Tag:
beaverbuild<br/>(0x95222290dd7278aa3ddd389cc1e1d165cc4bafe5)',
'Self': False,
'To': '0xd6e4aa932147a3fe5311da1b67d9e73da06f9cef',
'Value': '0.04264153 ETH',
'Txn Fee': '0.00133034',
'GasPrice': '47.24401969',
'Error': ''}
```

تابع get\_page\_count

تگ مربوط به را پیدا می کنیم و مقدار آن را بر می گردانیم.

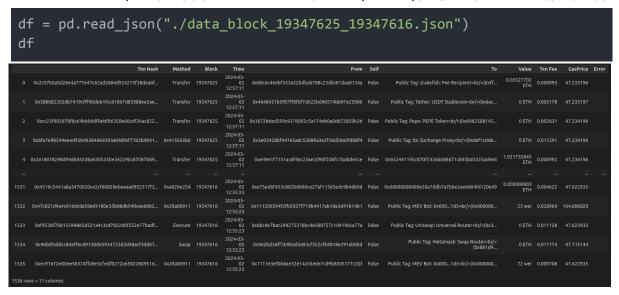
```
def get_page_count(the_soup):
    return int(the_soup.find(class_="page-link
text-nowrap").text.split()[3])
```

## آنالیز داده ها

در این قسمت باید داده هایی که در قسمت قبل گرفتیم را آنالیز کنیم.

### بارگذاری داده ها

برای بارگذاری داده ها کار خاصی لازم به انجام نیست و فقط کافیست کد زیر را اجرا کنیم:



#### یاکسازی داده ها

با توجه به مواردی که توضیح دادیم در داده ها، داده تکراری نداریم فقط مشکلی که وجود دارد این است که ارزش معامله گاهی به نوان -۱۸ اتر ارزش دارد پس با کد زیر داده ها را تبدیل می کنیم:

همچنین ستون های زمان را از قالب رشته به قالب زمان می بریم:

```
df["Time"] = pd.to_datetime(df["Time"])
```

## آنالیز آماری

در این قسمت متغیر های ارزش معامله و مالیات معامله را مورد بررسی قرار می دهیم. جدول زیر برخی از متغیر های آماری مربوط به داده ها را نشان می دهد.

متخد آدا م	راکنش های صفر	با در نظر گرفتن ت	در نظر گرفتن تراکنش های صفر با در نظر گ			
متغیر آماری	Value	Txn Fee	Value	Txn Fee		
میانگین	0.670632	0.005073	1.459054	0.003097		
میانه	0.000000	0.002366	0.057348	0.001066		
انحراف معيار	13.044758	0.009911	19.211157	0.004013		
IQR	0.045676	0.004909	0.282837	0.004271		

mean         1.459054         0.003097         51.51685           std         19.224778         0.004016         18.34065           min         0.000000         0.000980         46.67801           25%         0.013132         0.001014         47.43437           50%         0.057349         0.001066         49.03339           75%         0.295970         0.005286         50.72486           max         500.000000         0.052443         361.50348		Value	Txn Fee	GasPrice
std 19.224778 0.004016 18.34065 min 0.000000 0.000980 46.67801 25% 0.013132 0.001014 47.43437 50% 0.057349 0.001066 49.03339 75% 0.295970 0.005286 50.72486 max 500.000000 0.052443 361.50348	count	706.000000	706.000000	706.000000
min 0.000000 0.000980 46.67801 25% 0.013132 0.001014 47.43437 50% 0.057349 0.001066 49.03339 75% 0.295970 0.005286 50.72486 max 500.000000 0.052443 361.50348	mean	1.459054	0.003097	51.516851
25% 0.013132 0.001014 47.43437 50% 0.057349 0.001066 49.03339 75% 0.295970 0.005286 50.72486 max 500.000000 0.052443 361.50348	std	19.224778	0.004016	18.340651
50% 0.057349 0.001066 49.03339 75% 0.295970 0.005286 50.72486 max 500.000000 0.052443 361.50348	min	0.000000	0.000980	46.678019
75% 0.295970 0.005286 50.72486 max 500.000000 0.052443 361.50348	25%	0.013132	0.001014	47.434373
max 500.000000 0.052443 361.50348	50%	0.057349	0.001066	49.033394
	75%	0.295970	0.005286	50.724862
median 0.057349 0.001066 49.03339	max	500.000000	0.052443	361.503483
	median	0.057349	0.001066	49.033394
IQR 0.282838 0.004271 3.29048	IQR	0.282838	0.004271	3.290489

with zero						
	Value	Txn Fee	GasPrice			
count	1536.000000	1536.000000	1536.000000			
mean	0.670633	0.005073	50.953806			
std	13.049007	0.009915	15.700495			
min	0.000000	0.000980	46.678019			
25%	0.000000	0.001082	47.301360			
50%	0.000000	0.002366	48.678019			
75%	0.045677	0.005992	50.301624			
max	500.000000	0.121668	361.503483			
median	0.000000	0.002366	48.678019			
IQR	0.045677	0.004909	3.000264			

#### نکات قابل توجه در داده ها:

- بیش از ۵۰ درصد داده ها صفر هستند.
- تفاوت میانه و میانگین بسیار زیاد است معادل ۱.۵ اتر یعنی چیزی حدود ۴۵۰۰\$!!! دلیل این موضوع این است که پارامتر هایی مانند میانگین به داده های پرت حساس هستند ولی میانه نیست همین موضوع برای IQR و انحراف معیار صادق است به طوری که از IQR می توان نتیجه گرفت اختلاف تبادلات ۲۸.۰ اتر است اما انحراف معیار ۱۹.۲۲ اتر این مقدار را محاسبه می کند.
  - برخلاف دو داده دیگر gas price میانگین و میانه نزدیک به یکدیگر دارد.
    - یک تبادل ۵۰۰ اتری معادل ۱.۸۰۰،۰۰۰\$ داریم.

15 | پروژه صفر درس مبانی علوم داده

بررسی بیشتر تبادل ۵۰۰ اتری

#### تبادل به شرح زیر است:



#### فرد فرستنده تبادلات زیر را داشته:

Txn Hash	Method	Block	Time	From	Self		Value	Txn Fee	GasPrice
677 0x0c8141f52e2009804a25e7a23ad68993af0a07179c0a	Transfer	19347621	2024-03-02 12:56:23	0x4196c40de33062ce03070f058922baa99b28157b	False	Public Tag: Lido: wstETH Token />(0x7f39c581	500.0	0.006144	50.747998
1300 0x845a2fdd441097b91044aea49f8261bdf5a48ddadea6	Withdraw ETH	19347617	2024-03-02 12:55:35	0x4196c40de33062ce03070f058922baa99b28157b	False	0x893411580e590d62ddbca8a703d61cc4a8c7b2b9			47.079028

#### فرد دریافت کننده را با اسمش جستجو کردیم و به تراکنش های زیر رسیدیم:

	Txn Hash	Method	Block	Time	From	Self	То	Value	Txn Fee	GasPrice
445	0xdfaf3e1ae4e26ef195cdecce7f483b20f63735a9f07b	Approve	19347623	2024-03-02 12:56:47	0x4dc921de85561bca35d33ca15c19f2e1e5043590	False	Public Tag: Lido: stETH Token c/>(0xae7ab9652	0.000000	0.002168	50.069108
470	0xbe991696be31477650f01ca7197bd0a471a655b25478	Transfer	19347623	2024-03-02 12:56:47	Public Tag: Binance 16 c/oxdfd5293d8e347dfe	False	Public Tag: Lido: LDO Token (0x5a98fcbea51	0.000000	0.006703	51.279108
496	0xed1f0965a9b24cc3e30375062f9ffdc1abb7b2e19388	Transfer	19347622	2024-03-02 12:56:35	Public Tag: Titan Builder or/>(0x4838b106fce96	False	Public Tag: Lido: Execution Layer Rewards Vaul	0.056132	0.001101	49.809176
677	0x0c8141f52e2009804a25e7a23ad68993af0a07179c0a	Transfer	19347621	2024-03-02 12:56:23	0x4196c40de33062ce03070f058922baa99b28157b	False	Public Tag: Lido: wstETH Token -(0x7f39c581	500.000000	0.006144	50.747998
705	0xb3dbe655b904df10da63534bf96a1641baf3a28925e9	Approve	19347621	2024-03-02 12:56:23	0xaeddc5c90df91d8a9f1e9ec96aee93e64c8f045a	False	Public Tag: Lido: stETH Token or/>(0xae7ab9652	0.000000	0.003328	50.742275
903	0x23589249d4e5beeac45f0ca096221abeb8e0d7d32c8b	Approve	19347620	2024-03-02 12:56:11	0xe81032708386337d65678303678caf2597f315e9	False	Public Tag: Lido: stETH Token c/oxae7ab9652	0.000000	0.003102	47.302860
956	0x05434d3467ade2997c5ce99715b64ef3e4cc9169a9db	Transfer	19347619	2024-03-02 12:55:59	Public Tag: Faith Builder y(0x5124fcc2b3f99	False	Public Tag: Lido: Execution Layer Rewards Vaul		0.001068	48.291462

نام دریافت کننده را در اینترنت جستجو می کنیم و می بینیم که بزرگ ترین pool شبکه اتریوم هست و دارایی ای معادل ۳۵۰۰۰۰۰۰۰۰۰ دارد.



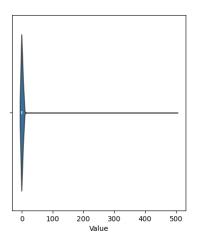
## بصری سازی داده ها

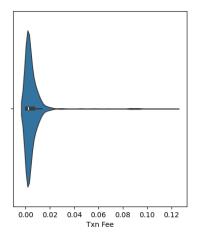
ما بصری سازی داده را در ۳ حالت انجام می دهیم:

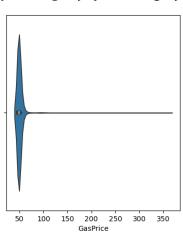
- داده های خام
- لگاریتم داده ها
- لگاریتم داده ها با حذف صفر ها

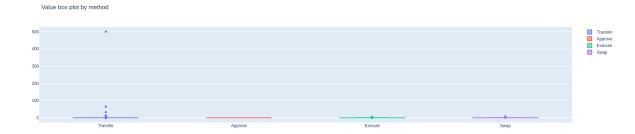
### داده های خام

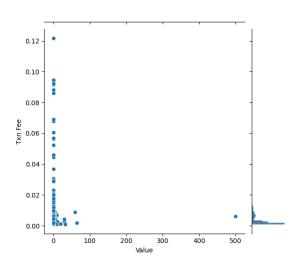
#### در این حالت نمودار های معنا داری نمی گیریم اما نمودار ها به شرح زیر هستند:



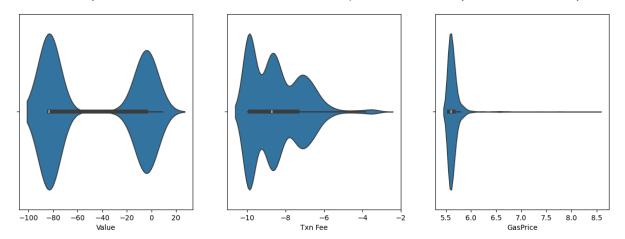






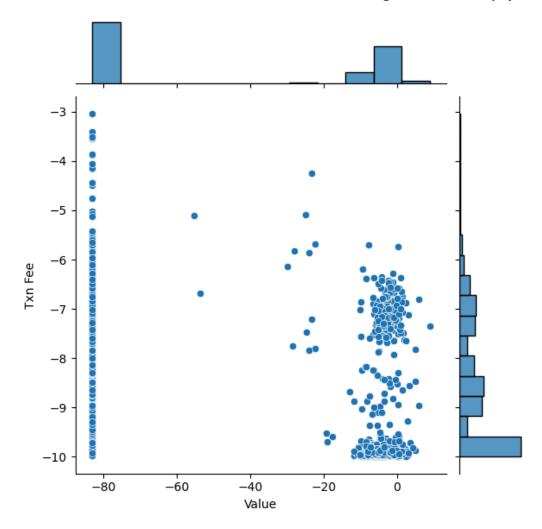


لگاریتم داده ها را می گیریم و برای ۰ ها مقدار اپسیلون (۱۰ به توان منفی ۲۵) را قرار می دهیم.

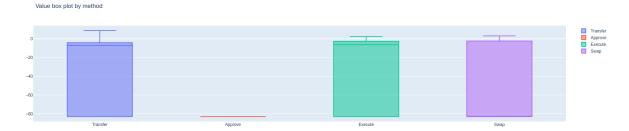


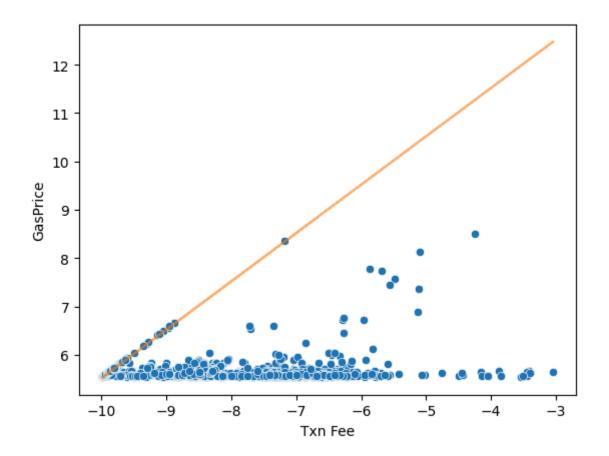
از نمودار ویالون موارد زیر را متوجه می شویم:

- نمودار value مدالیتی bimodal است. (به دلیل داده های صفر)
  - نمودار txn fee مدالیتی multimodal است.
  - نمودار gas price مدالیتی unimodal است.



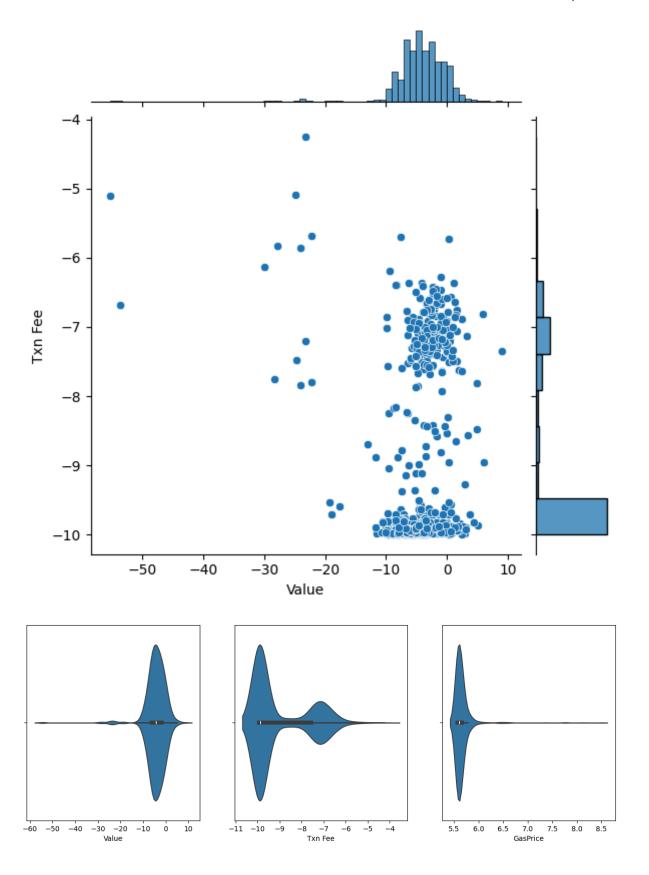
در سمت چپ نمودار بالا داده های صفر تجمیع شده اند.





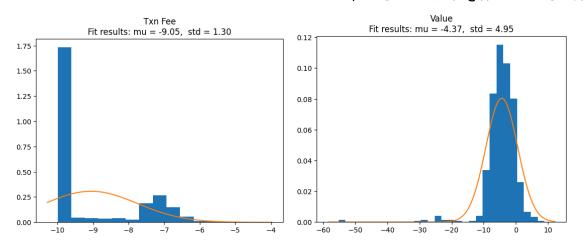
در نمودار بالا به نظر می آید که رابطه زیر برقرار است.  $\textit{GasPrice} \ \leq \ \textit{TxnFee} \ + \ \textit{C}$ 

لگاریتم داده ها با حذف صفر ها





### روی این داده ها توزیع نرمال فیت می کنیم:



همانطور که می بینید value تقریبا از توزیع نرمال پیروی می کند ولی txn fee اینطور نیست.